ĐẠI SỐ TUYẾN TÍNH

VÀ CÁC ỨNG DỤNG

CHƯƠNG 5

KHÔNG GIAN VECTOR $\mathbb{R}^n$

(Vector Space $\mathbb{R}^n$)

Bản dịch tiếng Việt

Nguyên tác: **W. Keith Nicholson**

Linear Algebra with Applications, Open Edition

Version 2023 — Revision A

Giấy phép và ghi công (License & Attribution)

Chương này được dịch (adapted) từ nguyên tác *Linear Algebra with Applications* của W. Keith Nicholson và Lyryx Learning Inc. Xem bản gốc miễn phí tại `https://lyryx.com/linear-algebra-applications/`.

Tóm tắt thay đổi: Toàn bộ nội dung lý thuyết Chương 5 được dịch từ tiếng Anh sang tiếng Việt. Bổ sung bảng đối chiếu thuật ngữ Anh–Việt và ghi chú cho người học. Các ký hiệu toán học, công thức và ví dụ giữ nguyên theo bản gốc.

Giấy phép: Creative Commons Attribution-NonCommercial-ShareAlike 4.0 (CC BY-NC-SA 4.0) — `http://creativecommons.org/licenses/by-nc-sa/4.0/`. Bản dịch này được phát hành theo cùng giấy phép với bản gốc.

Trích dẫn nguyên tác: Nicholson, W. Keith. *Linear Algebra with Applications*, Version 2023 – Revision A. Vretta-Lyryx Inc., Calgary, Alberta, Canada, July 1, 2023.

Đọc trước khi bắt đầu — vì sao Chương 5 khó hơn

Chương 5 là chỗ đại số tuyến tính chuyển từ *tính toán* sang *tư duy trừu tượng*. Ở Chương 1–4 bạn giải hệ, nhân ma trận, tính định thức — đều là những việc "làm được bằng tay". Từ đây, bạn sẽ làm việc với các *tập hợp* vector và các *tính chất* của chúng.
Đừng nản nếu thấy khó hơn hẳn. Đây là cảm giác bình thường và gần như ai cũng trải qua. Vài lời khuyên:

- **Luôn giữ hình ảnh trong đầu.** Không gian con trong $\mathbb{R}^3$ chỉ có 4 loại: điểm gốc, đường thẳng qua gốc, mặt phẳng qua gốc, và cả $\mathbb{R}^3$. Mỗi khi gặp khái niệm mới, hãy hỏi "trong $\mathbb{R}^3$ thì nó trông thế nào?"
- **Định nghĩa là công cụ, không phải thứ để thuộc lòng.** Khi cần chứng minh U là không gian con, bạn chỉ việc kiểm tra ba điều kiện S1, S2, S3. Rất máy móc.
- **Chương này là nền của machine learning.** Hạng, cơ sở, số chiều, trực giao, bình phương tối thiểu — đó chính là ngôn ngữ của PCA, hồi quy, nén dữ liệu.

Bảng đối chiếu thuật ngữ Anh–Việt (Chương 5)

Tiếng Anh	Tiếng Việt	Giải thích ngắn
set	tập hợp	Một bộ sưu tập các đối tượng.
subset ($X \subseteq Y$)	tập con	Mọi phần tử của X đều thuộc Y.
subspace	không gian con	Tập con thoả S1, S2, S3 (chứa $\mathbf{0}$, đóng với $+$ và $\times$).
closed under addition	đóng với phép cộng	Cộng hai phần tử vẫn ở trong tập.
zero subspace	không gian con không	$\{\mathbf{0}\}$.
proper subspace	không gian con thực sự	Khác $\{\mathbf{0}\}$ và khác toàn bộ $\mathbb{R}^n$.
null space	không gian không (hạt nhân)	$\operatorname{null} A = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{0}\}$.
image space / column space	không gian ảnh / không gian cột	$\operatorname{im} A = \{A\mathbf{x}\}$.
eigenspace	không gian riêng	$E_\lambda(A) = \operatorname{null}(\lambda I - A)$.
span	bao tuyến tính (span)	Tập mọi tổ hợp tuyến tính.
spanning set	tập sinh	Tập vector mà span của nó là cả không gian.
linearly independent	độc lập tuyến tính	Chỉ tổ hợp tầm thường mới cho $\mathbf{0}$.
linearly dependent	phụ thuộc tuyến tính	Tồn tại tổ hợp khác tầm thường bằng $\mathbf{0}$.
basis	cơ sở	Tập vừa độc lập tuyến tính vừa sinh.
dimension	số chiều	Số vector trong một cơ sở bất kỳ.
standard basis	cơ sở chính tắc	Các cột của I_n.
rank	hạng	Số chiều của không gian cột (= số 1 dẫn đầu).
row space	không gian hàng	Span của các hàng.
column space	không gian cột	Span của các cột ($= \operatorname{im} A$).
nullity	số khuyết	$\dim(\operatorname{null} A)$.
Rank-Nullity Theorem	định lý hạng–số khuyết	$\operatorname{rank} A + \dim(\operatorname{null} A) = n$.
orthogonal set	tập trực giao	Các vector đôi một vuông góc.
orthonormal set	tập trực chuẩn	Trực giao và mỗi vector có độ dài 1.
orthogonal basis	cơ sở trực giao	Cơ sở gồm các vector đôi một vuông góc.
Gram–Schmidt	Gram–Schmidt	Thuật toán trực giao hoá.
orthogonal complement	phần bù trực giao	$U^\perp$: mọi vector vuông góc với U.
similar matrices	ma trận đồng dạng	$B = P^{-1}AP$.
trace	vết	Tổng các phần tử đường chéo.
best approximation	xấp xỉ tốt nhất	Điểm gần nhất trong một không gian con.
least squares	bình phương tối thiểu	Nghiệm gần đúng khi hệ vô nghiệm.
normal equations	hệ phương trình chuẩn	$A^TAz = A^Tb$.
variance / standard deviation	phương sai / độ lệch chuẩn	Đo độ phân tán dữ liệu.
correlation	hệ số tương quan	Đo mức liên hệ tuyến tính giữa hai biến.

Chương 5 — Không gian vector $\mathbb{R}^n$

5.1 Không gian con và tập sinh

(Subspaces and Spanning)

Trong chương này ta khảo sát $\mathbb{R}^n$ ở dạng tổng quát đầy đủ, và giới thiệu một số khái niệm cùng phương pháp quan trọng nhất của đại số tuyến tính.

Không gian con của $\mathbb{R}^n$

Định nghĩa 5.1 — Không gian con của $\mathbb{R}^n$

Một tập U các vector trong $\mathbb{R}^n$ được gọi là **không gian con** (*subspace*) của $\mathbb{R}^n$ nếu nó thoả các tính chất sau:

S1. Vector không $\mathbf{0} \in U$.

S2. Nếu $\mathbf{x} \in U$ và $\mathbf{y} \in U$ thì $\mathbf{x} + \mathbf{y} \in U$.

S3. Nếu $\mathbf{x} \in U$ thì $a\mathbf{x} \in U$ với mọi số thực a.

Ta nói tập con U **đóng với phép cộng** nếu S2 đúng, và **đóng với phép nhân vô hướng** nếu S3 đúng.

Rõ ràng $\mathbb{R}^n$ là không gian con của chính nó. Tập $U = \{\mathbf{0}\}$, chỉ gồm vector không, cũng là không gian con vì $\mathbf{0} + \mathbf{0} = \mathbf{0}$ và $a\mathbf{0} = \mathbf{0}$; nó được gọi là **không gian con không**. Mọi không gian con của $\mathbb{R}^n$ khác $\{\mathbf{0}\}$ và khác $\mathbb{R}^n$ được gọi là **không gian con thực sự** (*proper subspace*).

Ta đã thấy ở Mục 4.2 rằng mọi mặt phẳng M qua gốc toạ độ trong $\mathbb{R}^3$ có phương trình $ax + by + cz = 0$ với a, b, c không đồng thời bằng 0. Ở đây $\mathbf{n} = \begin{bmatrix} a \\ b \\ c \end{bmatrix}$ là pháp tuyến và

$$M = \{\mathbf{v} \text{ trong } \mathbb{R}^3 \mid \mathbf{n} \cdot \mathbf{v} = 0\}$$

Khi đó M là không gian con của $\mathbb{R}^3$. Thật vậy:

S1. $\mathbf{0} \in M$ vì $\mathbf{n} \cdot \mathbf{0} = 0$;

S2. Nếu $\mathbf{v} \in M$ và $\mathbf{v}_1 \in M$ thì $\mathbf{n} \cdot (\mathbf{v} + \mathbf{v}_1) = 0 + 0 = 0$, nên $\mathbf{v} + \mathbf{v}_1 \in M$;

S3. Nếu $\mathbf{v} \in M$ thì $\mathbf{n} \cdot (a\mathbf{v}) = a(\mathbf{n} \cdot \mathbf{v}) = 0$, nên $a\mathbf{v} \in M$.

Ví dụ 5.1.1

Các mặt phẳng và đường thẳng qua gốc toạ độ trong $\mathbb{R}^3$ đều là không gian con của $\mathbb{R}^3$.
Lời giải. Ta đã xử lý mặt phẳng ở trên. Nếu L là đường thẳng qua gốc với vector chỉ phương $\mathbf{d}$ thì $L = \{t\mathbf{d} \mid t \in \mathbb{R}\}$, và việc kiểm tra S1, S2, S3 dành làm bài tập.

Ví dụ 5.1.1 cho thấy các đường thẳng qua gốc trong $\mathbb{R}^2$ là không gian con; thực ra chúng là những không gian con thực sự *duy nhất* của $\mathbb{R}^2$. Và ta sẽ thấy ở Ví dụ 5.2.14 rằng đường thẳng và mặt phẳng qua gốc trong $\mathbb{R}^3$ là những không gian con thực sự duy nhất của $\mathbb{R}^3$. Như vậy hình học của đường thẳng và mặt phẳng qua gốc được nắm bắt trọn vẹn bởi khái niệm không gian con.

Không gian con cũng dùng để mô tả các đặc trưng quan trọng của ma trận A cỡ $m \times n$. **Không gian không** (hay **hạt nhân**) của A, ký hiệu $\operatorname{null} A$, và **không gian ảnh** của A, ký hiệu $\operatorname{im} A$, được định nghĩa bởi

$$\operatorname{null} A = \{\mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} = \mathbf{0}\} \qquad \text{và} \qquad \operatorname{im} A = \{A\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n\}$$

Theo ngôn ngữ Chương 2, $\operatorname{null} A$ gồm mọi nghiệm của hệ thuần nhất $A\mathbf{x} = \mathbf{0}$, còn $\operatorname{im} A$ là tập mọi vector $\mathbf{y}$ sao cho $A\mathbf{x} = \mathbf{y}$ có nghiệm.

Ví dụ 5.1.2

Nếu A là ma trận $m \times n$ thì:

1. $\operatorname{null} A$ là không gian con của $\mathbb{R}^n$.
2. $\operatorname{im} A$ là không gian con của $\mathbb{R}^m$.

Lời giải.
(1) $\mathbf{0} \in \operatorname{null} A$ vì $A\mathbf{0} = \mathbf{0}$. Nếu $\mathbf{x}$ và $\mathbf{x}_1$ thuộc $\operatorname{null} A$ thì

$$A(\mathbf{x} + \mathbf{x}_1) = \mathbf{0} + \mathbf{0} = \mathbf{0} \quad \text{và} \quad A(a\mathbf{x}) = a\mathbf{0} = \mathbf{0}$$

Vậy $\operatorname{null} A$ thoả S1, S2, S3.
(2) $\mathbf{0} \in \operatorname{im} A$ vì $\mathbf{0} = A\mathbf{0}$. Giả sử $\mathbf{y}$ và $\mathbf{y}_1$ thuộc $\operatorname{im} A$, chẳng hạn $\mathbf{y} = A\mathbf{x}$ và $\mathbf{y}_1 = A\mathbf{x}_1$. Khi đó

$$\mathbf{y} + \mathbf{y}_1 = A(\mathbf{x} + \mathbf{x}_1) \quad \text{và} \quad a\mathbf{y} = A(a\mathbf{x})$$

cho thấy cả hai đều thuộc $\operatorname{im} A$.

Nếu A là ma trận $n \times n$ và λ là số bất kỳ, đặt

$$E_\lambda(A) = \{\mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} = \lambda\mathbf{x}\}$$

Một vector $\mathbf{x}$ thuộc $E_\lambda(A)$ khi và chỉ khi $(\lambda I - A)\mathbf{x} = \mathbf{0}$, nên Ví dụ 5.1.2 cho:

Ví dụ 5.1.3

$E_\lambda(A) = \operatorname{null}(\lambda I - A)$ là không gian con của $\mathbb{R}^n$ với mọi ma trận A cỡ $n \times n$ và mọi số λ.

$E_\lambda(A)$ được gọi là **không gian riêng** của A ứng với λ. Lý do của tên gọi: λ là giá trị riêng của A khi và chỉ khi $E_\lambda(A) \neq \{\mathbf{0}\}$. Khi đó các vector khác không trong $E_\lambda(A)$ chính là các vector riêng của A ứng với λ.

Bạn đọc không nên có ấn tượng rằng *mọi* tập con của $\mathbb{R}^n$ đều là không gian con. Ví dụ:

$$U_1 = \left\{ \begin{bmatrix} x \\ y \end{bmatrix} \,\middle|\, x \geq 0 \right\} \text{ thoả S1 và S2, nhưng không thoả S3;}$$

$$U_2 = \left\{ \begin{bmatrix} x \\ y \end{bmatrix} \,\middle|\, x^2 = y^2 \right\} \text{ thoả S1 và S3, nhưng không thoả S2.}$$

Do đó cả U_1 lẫn U_2 đều không phải không gian con của $\mathbb{R}^2$.

Ghi chú cho người học — trực giác về "không gian con"

Hãy hình dung không gian con là một "không gian phẳng đi qua gốc toạ độ". Ba điều kiện S1–S3 nói chính xác điều đó:

- S1: phải chứa gốc. Đây là lý do mặt phẳng $x+y+z=1$ *không* phải không gian con — nó không đi qua gốc.
- S2 + S3: "phẳng" — đi theo hướng nào trong tập, kéo dài bao xa cũng vẫn ở trong tập, và cộng hai hướng lại cũng vậy. Không có chỗ cong, không có biên.

Hai phản ví dụ U_1, U_2 ở trên rất đáng nhớ: U_1 là nửa mặt phẳng (có *biên*, nên nhân với -1 là ra ngoài), U_2 là hai đường thẳng cắt nhau (cộng hai điểm trên hai đường khác nhau là ra ngoài).
Trong machine learning, $\operatorname{im} A$ (không gian cột) là tập *mọi kết quả có thể* mà mô hình tuyến tính của bạn tạo ra được, còn $\operatorname{null} A$ là tập các input bị mô hình "nén về 0" — tức thông tin bị mất. Hai không gian này quyết định mô hình của bạn mạnh hay yếu.

Tập sinh (Spanning Sets)

Cho $\mathbf{v}$ và $\mathbf{w}$ là hai vector khác không, không song song trong $\mathbb{R}^3$ với gốc tại gốc toạ độ. Mặt phẳng M qua gốc chứa hai vector này đã được mô tả ở Mục 4.2 bằng pháp tuyến $\mathbf{n}=\mathbf{v}\times\mathbf{w}$. Nhưng có một cách tiếp cận khác ít nhất cũng hữu ích như vậy trong $\mathbb{R}^3$ và, quan trọng hơn, hoạt động với *mọi* không gian con của $\mathbb{R}^n$.

Ý tưởng: một vector $\mathbf{p}$ nằm trong M khi và chỉ khi nó có dạng

$$\mathbf{p}=a\mathbf{v}+b\mathbf{w}$$

với các số thực a, b nào đó (ta nói $\mathbf{p}$ là *tổ hợp tuyến tính* của $\mathbf{v}$ và $\mathbf{w}$). Do đó ta có thể mô tả M là

$$M=\{a\mathbf{v}+b\mathbf{w}\mid a,b\in\mathbb{R}\}$$

và ta nói $\{\mathbf{v},\mathbf{w}\}$ là một **tập sinh** cho M.

Định nghĩa 5.2 — Tổ hợp tuyến tính và span trong $\mathbb{R}^n$

Tập tất cả các tổ hợp tuyến tính của $\mathbf{x}_1,\dots,\mathbf{x}_k$ được gọi là **bao tuyến tính** (*span*) của các $\mathbf{x}_i$ và ký hiệu

$$\operatorname{span}\{\mathbf{x}_1,\dots,\mathbf{x}_k\}=\{t_1\mathbf{x}_1+t_2\mathbf{x}_2+\cdots+t_k\mathbf{x}_k\mid t_i\in\mathbb{R}\}$$

Nếu $V=\operatorname{span}\{\mathbf{x}_1,\dots,\mathbf{x}_k\}$, ta nói V được **sinh** bởi các vector $\mathbf{x}_1,\dots,\mathbf{x}_k$.

Hai ví dụ: $\operatorname{span}\{\mathbf{x}\}=\{t\mathbf{x}\mid t\in\mathbb{R}\}$, viết gọn là $\mathbb{R}\mathbf{x}$; và $\operatorname{span}\{\mathbf{x},\mathbf{y}\}=\{r\mathbf{x}+s\mathbf{y}\}$.

Nói riêng, nếu $\mathbf{v}$ và $\mathbf{w}$ là hai vector khác không, không song song trong $\mathbb{R}^3$ thì $M=\operatorname{span}\{\mathbf{v},\mathbf{w}\}$ là mặt phẳng chứa chúng. Còn nếu $\mathbf{d}$ là vector khác không bất kỳ thì $L=\operatorname{span}\{\mathbf{d}\}=\mathbb{R}\mathbf{d}$ là đường thẳng với vector chỉ phương $\mathbf{d}$. Vậy đường thẳng và mặt phẳng đều mô tả được bằng tập sinh.

Ví dụ 5.1.4

Cho $\mathbf{x}=(2,-1,2,1)$ và $\mathbf{y}=(3,4,-1,1)$ trong $\mathbb{R}^4$. Xác định xem $\mathbf{p}=(0,-11,8,1)$ hay $\mathbf{q}=(2,3,1,2)$ có thuộc $U=\operatorname{span}\{\mathbf{x},\mathbf{y}\}$ không.
Lời giải. $\mathbf{p}$ thuộc U khi và chỉ khi $\mathbf{p}=s\mathbf{x}+t\mathbf{y}$ với các vô hướng s, t. So sánh các thành phần cho

$$2s+3t=0,\quad -s+4t=-11,\quad 2s-t=8,\quad s+t=1$$

Hệ này có nghiệm $s=3$, $t=-2$, nên $\mathbf{p}$ thuộc U. Mặt khác, đòi hỏi $\mathbf{q}=s\mathbf{x}+t\mathbf{y}$ dẫn đến

$$2s+3t=2,\quad -s+4t=3,\quad 2s-t=1,\quad s+t=2$$

và hệ này vô nghiệm. Vậy **q** *không* thuộc U.

Định lý 5.1.1 — Định lý về span

Cho $U = \text{span}\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ trong $\mathbb{R}^n$. Khi đó:

1. U là không gian con của $\mathbb{R}^n$ chứa mỗi $\mathbf{x}_i$.
2. Nếu W là không gian con của $\mathbb{R}^n$ và mỗi $\mathbf{x}_i \in W$ thì $U \subseteq W$.

Chứng minh.

(1) $\mathbf{0} \in U$ vì $\mathbf{0} = 0\mathbf{x}_1 + \cdots + 0\mathbf{x}_k$. Nếu $\mathbf{x} = \sum t_i\mathbf{x}_i$ và $\mathbf{y} = \sum s_i\mathbf{x}_i$ thuộc U thì

$$\mathbf{x} + \mathbf{y} = \sum (t_i + s_i)\mathbf{x}_i \quad \text{và} \quad a\mathbf{x} = \sum (at_i)\mathbf{x}_i$$

đều thuộc U. Cuối cùng mỗi $\mathbf{x}_i$ thuộc U, nên S1, S2, S3 đều thoả.

(2) Cho $\mathbf{x} = \sum t_i\mathbf{x}_i$ với mỗi $\mathbf{x}_i \in W$. Khi đó mỗi $t_i\mathbf{x}_i \in W$ vì W thoả S3. Nhưng rồi $\mathbf{x} \in W$ vì W thoả S2. ■

Điều kiện (2) có thể diễn đạt là: $\text{span}\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ là không gian con *nhỏ nhất* của $\mathbb{R}^n$ chứa mỗi $\mathbf{x}_i$. Điều này hữu ích để chứng minh hai không gian con bằng nhau.

Ví dụ 5.1.5

Nếu $\mathbf{x}$ và $\mathbf{y}$ thuộc $\mathbb{R}^n$, hãy chứng tỏ $\text{span}\{\mathbf{x}, \mathbf{y}\} = \text{span}\{\mathbf{x} + \mathbf{y}, \mathbf{x} - \mathbf{y}\}$.
Lời giải. Vì cả $\mathbf{x} + \mathbf{y}$ và $\mathbf{x} - \mathbf{y}$ đều thuộc $\text{span}\{\mathbf{x}, \mathbf{y}\}$, Định lý 5.1.1 cho

$$\text{span}\{\mathbf{x} + \mathbf{y}, \mathbf{x} - \mathbf{y}\} \subseteq \text{span}\{\mathbf{x}, \mathbf{y}\}$$

Nhưng $\mathbf{x} = \frac{1}{2}(\mathbf{x} + \mathbf{y}) + \frac{1}{2}(\mathbf{x} - \mathbf{y})$ và $\mathbf{y} = \frac{1}{2}(\mathbf{x} + \mathbf{y}) - \frac{1}{2}(\mathbf{x} - \mathbf{y})$ đều thuộc $\text{span}\{\mathbf{x} + \mathbf{y}, \mathbf{x} - \mathbf{y}\}$, nên bao hàm ngược lại cũng đúng. Vậy hai span bằng nhau.

Nhắc lại cơ sở chính tắc $\{\mathbf{e}_1, \ldots, \mathbf{e}_n\}$ của $\mathbb{R}^n$ là tập các cột của I_n. Nếu $\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$ thì $\mathbf{x} = x_1\mathbf{e}_1 + \cdots + x_n\mathbf{e}_n$. Điều này chứng minh:

Ví dụ 5.1.6

$\mathbb{R}^n = \text{span}\{\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_n\}$, trong đó $\mathbf{e}_1, \ldots, \mathbf{e}_n$ là các cột của I_n.

Ví dụ 5.1.7

Cho ma trận A cỡ $m \times n$, gọi $\mathbf{x}_1, \ldots, \mathbf{x}_k$ là các nghiệm cơ bản của hệ $A\mathbf{x} = \mathbf{0}$ cho bởi thuật toán Gauss. Khi đó

$$\text{null}\, A = \text{span}\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$$

Lời giải. Nếu $\mathbf{x} \in \text{null}\, A$ thì $A\mathbf{x} = \mathbf{0}$, nên Định lý 1.3.2 cho thấy $\mathbf{x}$ là tổ hợp tuyến tính của các nghiệm cơ bản. Ngược lại, nếu $\mathbf{x} = \sum t_i\mathbf{x}_i$ thì $A\mathbf{x} = \sum t_i A\mathbf{x}_i = \mathbf{0}$. Vậy hai tập bằng nhau.

Ví dụ 5.1.8

Cho $\mathbf{c}_1, \ldots, \mathbf{c}_n$ là các cột của ma trận A cỡ $m \times n$. Khi đó

$$\operatorname{im} A = \operatorname{span}\{\mathbf{c}_1, \ldots, \mathbf{c}_n\}$$

Lời giải. Ta có $A\mathbf{e}_i = \mathbf{c}_i$, nên mỗi $\mathbf{c}_i$ thuộc $\operatorname{im} A$. Ngược lại, nếu $\mathbf{y} = A\mathbf{x}$ với $\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$ thì Định nghĩa 2.5 cho

$$\mathbf{y} = x_1\mathbf{c}_1 + x_2\mathbf{c}_2 + \cdots + x_n\mathbf{c}_n$$

thuộc $\operatorname{span}\{\mathbf{c}_1, \ldots, \mathbf{c}_n\}$. Vậy hai tập bằng nhau.

Ghi chú cho người học

Ví dụ 5.1.8 giải thích vì sao $\operatorname{im} A$ còn được gọi là **không gian cột** (*column space*) — nó chính là span của các cột của A. Đây là tên gọi bạn sẽ gặp nhiều hơn trong tài liệu tiếng Anh.
Kết hợp với Định lý 2.2.1, ta được một câu rất đáng nhớ:

$$\text{Hệ } A\mathbf{x} = \mathbf{b} \text{ có nghiệm } \iff \mathbf{b} \text{ nằm trong không gian cột của } A.$$

Toàn bộ Chương 1 về "hệ có nghiệm hay vô nghiệm" giờ được gói gọn trong một câu hình học.

5.2 Độc lập tuyến tính và số chiều

Có những tập sinh (spanning set) *tốt* hơn những tập sinh khác. Nếu $U = \operatorname{span}\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_k\}$ là một không gian con của $\mathbb{R}^n$, thì mọi vector trong U đều viết được thành tổ hợp tuyến tính của các $\mathbf{x}_i$ theo *ít nhất một* cách. Điều ta quan tâm ở đây là những tập sinh mà mỗi vector trong U có *đúng một* biểu diễn.

Độc lập tuyến tính (Linear Independence)

Cho $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_k$ trong $\mathbb{R}^n$, giả sử hai tổ hợp tuyến tính bằng nhau:

$$r_1\mathbf{x}_1 + r_2\mathbf{x}_2 + \cdots + r_k\mathbf{x}_k = s_1\mathbf{x}_1 + s_2\mathbf{x}_2 + \cdots + s_k\mathbf{x}_k$$

Ta đang tìm một điều kiện trên tập $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ bảo đảm biểu diễn này là *duy nhất*, tức là $r_i = s_i$ với mọi i. Chuyển hết sang vế trái:

$$(r_1 - s_1)\mathbf{x}_1 + (r_2 - s_2)\mathbf{x}_2 + \cdots + (r_k - s_k)\mathbf{x}_k = \mathbf{0}$$

Vậy điều kiện cần là: phương trình này *buộc* tất cả các hệ số $r_i - s_i$ phải bằng 0.

Định nghĩa 5.3 — Độc lập tuyến tính trong $\mathbb{R}^n$

Một tập $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_k\}$ các vector được gọi là **độc lập tuyến tính** (linearly independent), hay gọn là **độc lập**, nếu nó thỏa điều kiện:

$$\text{Nếu } t_1\mathbf{x}_1 + t_2\mathbf{x}_2 + \cdots + t_k\mathbf{x}_k = \mathbf{0} \text{ thì } t_1 = t_2 = \cdots = t_k = 0$$

Định lý 5.2.1

Nếu $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_k\}$ là một tập độc lập trong $\mathbb{R}^n$, thì mọi vector trong $\text{span}\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ có **duy nhất một** biểu diễn dưới dạng tổ hợp tuyến tính của các $\mathbf{x}_i$.

Nói bằng ngôn ngữ khác cho dễ nhớ. Ta nói một tổ hợp tuyến tính **triệt tiêu** (vanishes) nếu nó bằng vector không, và gọi tổ hợp tuyến tính đó là **tầm thường** (trivial) nếu mọi hệ số đều bằng 0. Khi đó định nghĩa độc lập phát biểu gọn lại:

Một tập vector là độc lập khi và chỉ khi tổ hợp tuyến tính duy nhất triệt tiêu là tổ hợp tầm thường.

Từ đó ta có quy trình kiểm tra tính độc lập:

Định lý — Phép kiểm tra độc lập (Independence Test)

Để xác minh tập $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_k\}$ trong $\mathbb{R}^n$ là độc lập, làm như sau:

1. Đặt một tổ hợp tuyến tính bằng không: $t_1\mathbf{x}_1 + t_2\mathbf{x}_2 + \cdots + t_k\mathbf{x}_k = \mathbf{0}$.
2. Chứng minh $t_i = 0$ với mọi i (tức tổ hợp đó là tầm thường).

Dĩ nhiên, nếu có *một* tổ hợp tuyến tính không tầm thường triệt tiêu thì các vector **không** độc lập.

Ví dụ 5.2.1

Xác định xem $\{(1,0,-2,5),\ (2,1,0,-1),\ (1,1,2,1)\}$ có độc lập trong $\mathbb{R}^4$ hay không.
Lời giải. Giả sử một tổ hợp tuyến tính triệt tiêu:

$$r(1,0,-2,5) + s(2,1,0,-1) + t(1,1,2,1) = (0,0,0,0)$$

So sánh từng thành phần tương ứng cho ta hệ bốn phương trình:

$$r + 2s + t = 0, \qquad s + t = 0, \qquad -2r + 2t = 0, \qquad 5r - s + t = 0$$

Nghiệm duy nhất là nghiệm tầm thường $r = s = t = 0$ (bạn hãy tự kiểm tra), nên các vector này độc lập theo phép kiểm tra độc lập.

Nhắc lại từ Định nghĩa 2.3: **cơ sở chuẩn tắc** (standard basis) của $\mathbb{R}^n$ là tập các cột của ma trận đơn vị I_n.

Ví dụ 5.2.2

Chứng minh cơ sở chuẩn tắc $\{\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_n\}$ của $\mathbb{R}^n$ là độc lập.
Lời giải. Các thành phần của $t_1\mathbf{e}_1 + t_2\mathbf{e}_2 + \cdots + t_n\mathbf{e}_n$ chính là $t_1, t_2, \ldots, t_n$. Vậy tổ hợp này triệt tiêu khi và chỉ khi mọi $t_i = 0$. Phép kiểm tra độc lập áp dụng được.

Ví dụ 5.2.3

Nếu $\{\mathbf{x}, \mathbf{y}\}$ độc lập, chứng minh $\{2\mathbf{x} + 3\mathbf{y},\ \mathbf{x} - 5\mathbf{y}\}$ cũng độc lập.
Lời giải. Nếu $s(2\mathbf{x}+3\mathbf{y}) + t(\mathbf{x}-5\mathbf{y}) = \mathbf{0}$, gom các số hạng lại được $(2s+t)\mathbf{x} + (3s-5t)\mathbf{y} = \mathbf{0}$. Vì $\{\mathbf{x}, \mathbf{y}\}$ độc lập nên tổ hợp này phải tầm thường, tức là $2s + t = 0$ và $3s - 5t = 0$. Hệ này chỉ có nghiệm tầm thường $s = t = 0$, đúng như cần chứng minh.

Ví dụ 5.2.4

Chứng minh vector không trong $\mathbb{R}^n$ không thuộc bất kỳ tập độc lập nào.
Lời giải. Không tập nào dạng $\{\mathbf{0}, \mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_k\}$ là độc lập, bởi vì ta có một tổ hợp triệt tiêu *không tầm thường*:

$$1 \cdot \mathbf{0} + 0\mathbf{x}_1 + 0\mathbf{x}_2 + \cdots + 0\mathbf{x}_k = \mathbf{0}$$

(hệ số đầu tiên là $1 \neq 0$).

Ví dụ 5.2.5

Cho $\mathbf{x}$ trong $\mathbb{R}^n$, chứng minh $\{\mathbf{x}\}$ độc lập khi và chỉ khi $\mathbf{x} \neq \mathbf{0}$.
Lời giải. Một tổ hợp triệt tiêu từ $\{\mathbf{x}\}$ có dạng $t\mathbf{x} = \mathbf{0}$, $t \in \mathbb{R}$. Điều này kéo theo $t = 0$ vì $\mathbf{x} \neq \mathbf{0}$.

Ví dụ sau sẽ cần dùng về sau.

Ví dụ 5.2.6

Chứng minh các hàng khác không của một ma trận bậc thang dòng (row-echelon matrix) R là độc lập.
Lời giải. Ta minh họa trường hợp có 3 số 1 dẫn đầu; trường hợp tổng quát tương tự. Giả sử R có dạng

$$R = \begin{bmatrix} 0 & 1 & * & * & * & * \\ 0 & 0 & 0 & 1 & * & * \\ 0 & 0 & 0 & 0 & 1 & * \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

trong đó $*$ là số không xác định. Gọi R_1, R_2, R_3 là các hàng khác không. Nếu $t_1R_1 + t_2R_2 + t_3R_3 = \mathbf{0}$, ta chứng minh lần lượt $t_1 = 0$, rồi $t_2 = 0$, cuối cùng $t_3 = 0$. Điều kiện trên trở thành

$$(0, t_1, *, *, *, *) + (0, 0, 0, t_2, *, *) + (0, 0, 0, 0, t_3, *) = (0, 0, 0, 0, 0, 0)$$

So sánh thành phần thứ hai cho $t_1 = 0$, nên điều kiện thành $t_2R_2 + t_3R_3 = \mathbf{0}$. Lập luận y hệt cho $t_2 = 0$. Cuối cùng còn $t_3R_3 = \mathbf{0}$ và ta được $t_3 = 0$.

Một tập vector trong $\mathbb{R}^n$ được gọi là **phụ thuộc tuyến tính** (linearly dependent), gọn là **phụ thuộc**, nếu nó *không* độc lập tuyến tính — tương đương, nếu có một tổ hợp tuyến tính không tầm thường triệt tiêu.

Ví dụ 5.2.7

Nếu $\mathbf{v}$ và $\mathbf{w}$ là các vector khác không trong $\mathbb{R}^3$, chứng minh $\{\mathbf{v}, \mathbf{w}\}$ phụ thuộc khi và chỉ khi $\mathbf{v}$ và $\mathbf{w}$ song song.
Lời giải. Nếu $\mathbf{v}$ và $\mathbf{w}$ song song, thì một vector là bội vô hướng của vector kia (Định lý 4.1.5), chẳng hạn $\mathbf{v} = a\mathbf{w}$. Khi đó tổ hợp không tầm thường $\mathbf{v} - a\mathbf{w} = \mathbf{0}$ triệt tiêu, nên $\{\mathbf{v}, \mathbf{w}\}$ phụ thuộc.
Ngược lại, nếu $\{\mathbf{v}, \mathbf{w}\}$ phụ thuộc, lấy $s\mathbf{v} + t\mathbf{w} = \mathbf{0}$ không tầm thường, giả sử $s \neq 0$. Khi đó $\mathbf{v} = -\frac{t}{s}\mathbf{w}$ nên $\mathbf{v}$ và $\mathbf{w}$ song song (theo Định lý 4.1.5). Lập luận tương tự nếu $t \neq 0$.

Từ đây ta mô tả được bằng hình học ý nghĩa của việc tập $\{\mathbf{u}, \mathbf{v}, \mathbf{w}\}$ trong $\mathbb{R}^3$ là độc lập. Lưu ý yêu cầu này kéo theo $\{\mathbf{v}, \mathbf{w}\}$ cũng độc lập (vì $a\mathbf{v} + b\mathbf{w} = \mathbf{0}$ nghĩa là $0\mathbf{u} + a\mathbf{v} + b\mathbf{w} = \mathbf{0}$), nên $M = \text{span}\{\mathbf{v}, \mathbf{w}\}$ là mặt phẳng chứa $\mathbf{v}$, $\mathbf{w}$ và $\mathbf{0}$.

Ví dụ 5.2.8

Cho $\mathbf{u}, \mathbf{v}, \mathbf{w}$ là các vector khác không trong $\mathbb{R}^3$ với $\{\mathbf{v}, \mathbf{w}\}$ độc lập. Chứng minh $\{\mathbf{u}, \mathbf{v}, \mathbf{w}\}$ độc lập khi và chỉ khi $\mathbf{u}$ *không* nằm trong mặt phẳng $M = \text{span}\{\mathbf{v}, \mathbf{w}\}$.
Lời giải. Nếu $\{\mathbf{u}, \mathbf{v}, \mathbf{w}\}$ độc lập, giả sử phản chứng $\mathbf{u}$ nằm trong M, tức $\mathbf{u} = a\mathbf{v} + b\mathbf{w}$ với $a, b \in \mathbb{R}$. Khi đó $1\mathbf{u} - a\mathbf{v} - b\mathbf{w} = \mathbf{0}$, mâu thuẫn với tính độc lập của $\{\mathbf{u}, \mathbf{v}, \mathbf{w}\}$.
Ngược lại, giả sử $\mathbf{u}$ không nằm trong M; ta phải chứng minh $\{\mathbf{u}, \mathbf{v}, \mathbf{w}\}$ độc lập. Nếu $r\mathbf{u} + s\mathbf{v} + t\mathbf{w} = \mathbf{0}$ với $r, s, t \in \mathbb{R}$, thì $r = 0$ — vì nếu không, $\mathbf{u} = -\frac{s}{r}\mathbf{v} + \frac{-t}{r}\mathbf{w}$ sẽ nằm trong M. Nhưng khi $r = 0$ thì $s\mathbf{v} + t\mathbf{w} = \mathbf{0}$, nên $s = t = 0$ theo giả thiết. Vậy $\{\mathbf{u}, \mathbf{v}, \mathbf{w}\}$ độc lập.

Hình trong sách gốc (trang 270)

Mục này có hai hình minh họa: một hình vẽ $\mathbf{u}$ *chĩa ra khỏi* mặt phẳng M (trường hợp độc lập), và một hình vẽ $\mathbf{u}$ *nằm trong* mặt phẳng M (trường hợp phụ thuộc). Bạn nên tự vẽ lại hai hình này — đây là bức tranh trực giác quan trọng nhất của toàn mục 5.2: **độc lập trong $\mathbb{R}^3$ nghĩa là ba vector không cùng nằm trên một mặt phẳng đi qua gốc**.

Theo Định lý về ma trận khả nghịch, các điều kiện sau là tương đương với ma trận A cỡ $n \times n$:

1. A khả nghịch.
2. Nếu $A\mathbf{x} = \mathbf{0}$ với $\mathbf{x}$ trong $\mathbb{R}^n$, thì $\mathbf{x} = \mathbf{0}$.
3. $A\mathbf{x} = \mathbf{b}$ có nghiệm $\mathbf{x}$ với mọi vector $\mathbf{b}$ trong $\mathbb{R}^n$.

Điều kiện 1 vô nghĩa nếu A không vuông, nhưng điều kiện 2 và 3 vẫn có nghĩa với ma trận A bất kỳ, và thực ra chúng liên quan trực tiếp tới tính độc lập và tính sinh. Thật vậy, nếu $\mathbf{c}_1, \mathbf{c}_2, \ldots, \mathbf{c}_n$ là các cột của A và $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$, thì

$$A\mathbf{x} = x_1\mathbf{c}_1 + x_2\mathbf{c}_2 + \cdots + x_n\mathbf{c}_n$$

theo Định nghĩa 2.5. Do đó điều kiện 2 tương đương với tính độc lập của $\{\mathbf{c}_1, \ldots, \mathbf{c}_n\}$ và điều kiện 3 tương đương với $\text{span}\{\mathbf{c}_1, \ldots, \mathbf{c}_n\} = \mathbb{R}^m$.

Định lý 5.2.2

Nếu A là ma trận $m \times n$, gọi $\{\mathbf{c}_1, \mathbf{c}_2, \ldots, \mathbf{c}_n\}$ là các cột của A.

1. $\{\mathbf{c}_1, \ldots, \mathbf{c}_n\}$ độc lập trong $\mathbb{R}^m$ khi và chỉ khi $A\mathbf{x} = \mathbf{0}$, $\mathbf{x}$ trong $\mathbb{R}^n$, kéo theo $\mathbf{x} = \mathbf{0}$.
2. $\mathbb{R}^m = \text{span}\{\mathbf{c}_1, \ldots, \mathbf{c}_n\}$ khi và chỉ khi $A\mathbf{x} = \mathbf{b}$ có nghiệm $\mathbf{x}$ với mọi vector $\mathbf{b}$ trong $\mathbb{R}^m$.

Với ma trận vuông A, Định lý 5.2.2 đặc trưng tính khả nghịch của A theo tính sinh và tính độc lập của các *cột*. Ta cũng cần bàn các khái niệm này cho *hàng*. Nếu $\mathbf{x}_1, \ldots, \mathbf{x}_k$ là các hàng $1 \times n$, ta định nghĩa $\text{span}\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ là tập mọi tổ hợp tuyến tính của các $\mathbf{x}_i$ (xem như ma trận), và nói $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ **độc lập tuyến tính** nếu tổ hợp triệt tiêu duy nhất là tổ hợp tầm thường (tương đương, nếu $\{\mathbf{x}_1^T, \ldots, \mathbf{x}_k^T\}$ độc lập trong $\mathbb{R}^n$).[1]

[1] Tốt nhất nên xem cột và hàng chỉ là hai *cách ký hiệu khác nhau* cho bộ n số có thứ tự. Phần thảo luận này sẽ trở nên thừa ở Chương 6, nơi ta định nghĩa khái niệm không gian vector tổng quát.

Định lý 5.2.3

Các mệnh đề sau là tương đương với ma trận A cỡ $n \times n$:

1. A khả nghịch.
2. Các **cột** của A độc lập tuyến tính.
3. Các **cột** của A sinh ra $\mathbb{R}^n$.
4. Các **hàng** của A độc lập tuyến tính.
5. Các **hàng** của A sinh ra tập mọi hàng $1 \times n$.

Chứng minh. Gọi $\mathbf{c}_1, \ldots, \mathbf{c}_n$ là các cột của A.

$(1) \Leftrightarrow (2)$. Theo Định lý 2.4.5, A khả nghịch khi và chỉ khi $A\mathbf{x} = \mathbf{0}$ kéo theo $\mathbf{x} = \mathbf{0}$; điều này đúng khi và chỉ khi $\{\mathbf{c}_1, \ldots, \mathbf{c}_n\}$ độc lập theo Định lý 5.2.2.

$(1) \Leftrightarrow (3)$. Lại theo Định lý 2.4.5, A khả nghịch khi và chỉ khi $A\mathbf{x} = \mathbf{b}$ có nghiệm với mọi cột $\mathbf{b}$ trong $\mathbb{R}^n$; điều này đúng khi và chỉ khi $\operatorname{span}\{\mathbf{c}_1, \ldots, \mathbf{c}_n\} = \mathbb{R}^n$ theo Định lý 5.2.2.

$(1) \Leftrightarrow (4)$. A khả nghịch khi và chỉ khi A^T khả nghịch (Hệ quả 2.4.1); điều này lại đúng khi và chỉ khi A^T có các cột độc lập (theo $(1) \Leftrightarrow (2)$); cuối cùng, mệnh đề này đúng khi và chỉ khi A có các hàng độc lập (vì các hàng của A là chuyển vị của các cột của A^T).

$(1) \Leftrightarrow (5)$. Chứng minh tương tự $(1) \Leftrightarrow (4)$. ■

Ví dụ 5.2.9

Chứng minh $S = \{(2, -2, 5),\ (-3, 1, 1),\ (2, 7, -4)\}$ độc lập trong $\mathbb{R}^3$.

Lời giải. Xét ma trận $A = \begin{bmatrix} 2 & -2 & 5 \\ -3 & 1 & 1 \\ 2 & 7 & -4 \end{bmatrix}$ với các vector trong S làm *hàng*. Tính toán thường quy cho $\det A = -117 \neq 0$, nên A khả nghịch. Do đó S độc lập theo Định lý 5.2.3. Lưu ý Định lý 5.2.3 cũng cho thấy $\mathbb{R}^3 = \operatorname{span} S$.

Ghi chú cho người học — vì sao "định thức khác 0" lại tiện đến thế

Ví dụ 5.2.9 là một mẹo thực dụng bạn nên nhớ: với đúng n vector trong $\mathbb{R}^n$, thay vì giải hệ phương trình để kiểm tra độc lập, chỉ cần *xếp chúng thành ma trận vuông và tính định thức*. $\det \neq 0 \Rightarrow$ độc lập *và* sinh ra $\mathbb{R}^n$ — hai kết luận trong một phép tính.
Nhưng chú ý giới hạn: mẹo này **chỉ áp dụng khi số vector đúng bằng** n. Với 3 vector trong $\mathbb{R}^4$ (Ví dụ 5.2.1) ma trận không vuông, không có định thức — bạn phải quay lại phép kiểm tra độc lập hoặc đưa về bậc thang dòng.
Trong code: `numpy.linalg.det(A)` hoạt động, nhưng với số thực dấu chấm động, "bằng 0" gần như không bao giờ xảy ra chính xác. Thực tế người ta dùng `numpy.linalg.matrix_rank(A)` — hàm này dựa trên SVD và có ngưỡng sai số hợp lý, ổn định hơn nhiều so với so sánh `det(A) == 0`.

Số chiều (Dimension)

Trong ngôn ngữ hình học thông thường, ta nói $\mathbb{R}^3$ là *3 chiều*, mặt phẳng là *2 chiều*, đường thẳng là *1 chiều*. Định lý tiếp theo là công cụ nền tảng để làm rõ ý tưởng "số chiều" này. Tầm quan trọng của nó khó mà phóng đại.

Định lý 5.2.4 — Định lý cơ bản (Fundamental Theorem)

Cho U là không gian con của $\mathbb{R}^n$. Nếu U được sinh bởi m vector, và nếu U chứa k vector độc lập tuyến tính, thì

$$k \leq m$$

Chứng minh được trình bày ở Định lý 6.3.2 với mức tổng quát cao hơn nhiều.

Cách nhớ Định lý cơ bản

Phát biểu gọn: *tập độc lập không bao giờ dài hơn tập sinh*.
Trực giác: tập sinh là "vật liệu thô" đủ để dựng nên toàn bộ U; tập độc lập là tập "không có vector nào thừa". Bạn không thể có nhiều thứ không-thừa hơn số vật liệu cần thiết để dựng cả không gian. Chẳng hạn trong $\mathbb{R}^3$: không thể tìm được 4 vector độc lập, vì $\mathbb{R}^3$ sinh bởi 3 vector $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$.

Định nghĩa 5.4 — Cơ sở của một không gian con của $\mathbb{R}^n$

Nếu U là không gian con của $\mathbb{R}^n$, một tập $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_m\}$ các vector trong U được gọi là một **cơ sở** (basis) của U nếu nó thỏa hai điều kiện:

1. $\{\mathbf{x}_1, \ldots, \mathbf{x}_m\}$ độc lập tuyến tính.
2. $U = \text{span}\{\mathbf{x}_1, \ldots, \mathbf{x}_m\}$.

Kết quả đáng chú ý nhất về cơ sở là:

Định lý 5.2.5 — Định lý bất biến (Invariance Theorem)

Nếu $\{\mathbf{x}_1, \ldots, \mathbf{x}_m\}$ và $\{\mathbf{y}_1, \ldots, \mathbf{y}_k\}$ đều là cơ sở của không gian con U của $\mathbb{R}^n$, thì $m = k$.

Chứng minh. Ta có $k \leq m$ theo Định lý cơ bản, vì $\{\mathbf{x}_1, \ldots, \mathbf{x}_m\}$ sinh ra U còn $\{\mathbf{y}_1, \ldots, \mathbf{y}_k\}$ độc lập. Tương tự, đổi vai trò $\mathbf{x}$ và $\mathbf{y}$ ta được $m \leq k$. Vậy $m = k$. ■

Định lý bất biến bảo đảm định nghĩa sau không mập mờ:

Định nghĩa 5.5 — Số chiều của một không gian con của $\mathbb{R}^n$

Nếu U là không gian con của $\mathbb{R}^n$ và $\{\mathbf{x}_1, \ldots, \mathbf{x}_m\}$ là *một cơ sở bất kỳ* của U, thì số m các vector trong cơ sở đó gọi là **số chiều** (dimension) của U, ký hiệu

$$\dim U = m$$

Tầm quan trọng của Định lý bất biến là: số chiều của U có thể xác định bằng cách *đếm số vector trong một cơ sở bất kỳ*.[2]

Nhắc lại cơ sở chuẩn tắc của $\mathbb{R}^n$ là $\{\mathbf{e}_1, \ldots, \mathbf{e}_n\}$, tập các cột của ma trận đơn vị. Ta có $\mathbb{R}^n = \text{span}\{\mathbf{e}_1, \ldots, \mathbf{e}_n\}$ (Ví dụ 5.1.6) và $\{\mathbf{e}_1, \ldots, \mathbf{e}_n\}$ độc lập (Ví dụ 5.2.2). Vậy nó đúng là một cơ sở theo thuật ngữ hiện tại:

Ví dụ 5.2.10

$\dim(\mathbb{R}^n) = n$ và $\{\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_n\}$ là một cơ sở.

[2] Ta sẽ chứng minh ở Định lý 5.2.6 rằng mọi không gian con của $\mathbb{R}^n$ thực sự đều có cơ sở.

Điều này khớp với cảm nhận hình học rằng $\mathbb{R}^2$ là hai chiều và $\mathbb{R}^3$ là ba chiều. Nó cũng nói $\mathbb{R}^1 = \mathbb{R}$ là một chiều, với $\{1\}$ là cơ sở. Quay lại các không gian con của $\mathbb{R}^n$, ta định nghĩa

$$\dim\{\mathbf{0}\} = 0$$

Điều này tương đương với việc nói $\{\mathbf{0}\}$ có một cơ sở *không chứa vector nào*. Cách đặt này hợp lý vì $\mathbf{0}$ không thể thuộc bất kỳ tập độc lập nào (Ví dụ 5.2.4).

Ví dụ 5.2.11

Cho $U = \left\{ \begin{bmatrix} r \\ s \\ r \end{bmatrix} \;\middle|\; r, s \in \mathbb{R} \right\}$. Chứng minh U là không gian con của $\mathbb{R}^3$, tìm một cơ sở và tính $\dim U$.

Lời giải. Rõ ràng $\begin{bmatrix} r \\ s \\ r \end{bmatrix} = r\mathbf{u} + s\mathbf{v}$ với $\mathbf{u} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ và $\mathbf{v} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$. Suy ra $U = \text{span}\{\mathbf{u}, \mathbf{v}\}$, do đó U là không gian con của $\mathbb{R}^3$.

Hơn nữa, nếu $r\mathbf{u} + s\mathbf{v} = \mathbf{0}$ thì $\begin{bmatrix} r \\ s \\ r \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$ nên $r = s = 0$. Vậy $\{\mathbf{u}, \mathbf{v}\}$ độc lập, và là một cơ sở của U. Do đó $\dim U = 2$.

Ví dụ 5.2.12

Cho $B = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$ là một cơ sở của $\mathbb{R}^n$. Nếu A là ma trận $n \times n$ khả nghịch, thì $D = \{A\mathbf{x}_1, A\mathbf{x}_2, \ldots, A\mathbf{x}_n\}$ cũng là một cơ sở của $\mathbb{R}^n$.

Lời giải. Lấy $\mathbf{x}$ trong $\mathbb{R}^n$. Khi đó $A^{-1}\mathbf{x}$ cũng trong $\mathbb{R}^n$ nên, vì B là cơ sở,

$$A^{-1}\mathbf{x} = t_1\mathbf{x}_1 + t_2\mathbf{x}_2 + \cdots + t_n\mathbf{x}_n \quad (t_i \in \mathbb{R})$$

Nhân trái bởi A cho $\mathbf{x} = t_1(A\mathbf{x}_1) + t_2(A\mathbf{x}_2) + \cdots + t_n(A\mathbf{x}_n)$, suy ra D sinh ra $\mathbb{R}^n$.

Để chứng minh độc lập, cho $s_1(A\mathbf{x}_1) + \cdots + s_n(A\mathbf{x}_n) = \mathbf{0}$. Khi đó $A(s_1\mathbf{x}_1 + \cdots + s_n\mathbf{x}_n) = \mathbf{0}$ nên nhân trái bởi A^{-1} cho $s_1\mathbf{x}_1 + \cdots + s_n\mathbf{x}_n = \mathbf{0}$. Tính độc lập của B cho mỗi $s_i = 0$, chứng tỏ D độc lập. Vậy D là một cơ sở của $\mathbb{R}^n$.

Ghi chú cho người học — Ví dụ 5.2.12 nói gì về đồ họa máy tính

Ví dụ 5.2.12 phát biểu: *một phép biến đổi khả nghịch biến cơ sở thành cơ sở.* Đây chính là lý do toán học khiến việc "đổi hệ tọa độ" trong đồ họa 3D hay robotics luôn hợp lệ: ma trận model/view/projection khả nghịch $\Rightarrow$ hệ trục mới vẫn là một hệ trục đầy đủ, không bị "bẹp" mất chiều nào.

Ngược lại, nếu ma trận *không* khả nghịch ($\det = 0$), ảnh của cơ sở sẽ bị sập xuống không gian con có số chiều thấp hơn — trong đồ họa là hiện tượng mô hình bị dẹt thành mặt phẳng hoặc biến mất. Khi debug một scene 3D bị "mất vật thể", kiểm tra định thức của ma trận biến đổi là một trong những việc đầu tiên nên làm.

Tuy đã tìm được cơ sở trong nhiều không gian con của $\mathbb{R}^n$, ta chưa chứng minh *mọi* không gian con đều có cơ sở. Đó là một phần của định lý sau, chứng minh được hoãn tới Mục 6.4 (Định lý 6.4.1) nơi nó sẽ được chứng minh tổng quát hơn.

Định lý 5.2.6

Cho $U \neq \{\mathbf{0}\}$ là một không gian con của $\mathbb{R}^n$. Khi đó:

1. U có một cơ sở và $\dim U \leq n$.
2. Mọi tập độc lập trong U đều có thể **mở rộng** (bằng cách thêm vector từ một cơ sở cố định bất kỳ của U) thành một cơ sở của U, nếu nó chưa là cơ sở.
3. Mọi tập sinh của U đều có thể **rút gọn** (bằng cách bỏ bớt vector) thành một cơ sở của U, nếu nó chưa là cơ sở.

Ví dụ 5.2.13

Tìm một cơ sở của $\mathbb{R}^4$ chứa $S = \{\mathbf{u}, \mathbf{v}\}$ với $\mathbf{u} = (0, 1, 2, 3)$ và $\mathbf{v} = (2, -1, 0, 1)$.
Lời giải. Theo Định lý 5.2.6, ta có thể tìm cơ sở như vậy bằng cách thêm vector từ cơ sở chuẩn tắc của $\mathbb{R}^4$ vào S. Thử $\mathbf{e}_1 = (1, 0, 0, 0)$, ta thấy ngay $\{\mathbf{e}_1, \mathbf{u}, \mathbf{v}\}$ độc lập.
Giờ thêm một vector nữa từ cơ sở chuẩn tắc, chẳng hạn $\mathbf{e}_2$. Lại thấy $B = \{\mathbf{e}_1, \mathbf{e}_2, \mathbf{u}, \mathbf{v}\}$ độc lập. Vì B có $4 = \dim \mathbb{R}^4$ vector, B phải sinh ra $\mathbb{R}^4$ theo Định lý 5.2.7 dưới đây (hoặc bạn kiểm tra trực tiếp). Vậy B là một cơ sở của $\mathbb{R}^4$.

Định lý 5.2.6 có nhiều hệ quả hữu ích. Đây là hệ quả đầu tiên.

Định lý 5.2.7

Cho U là không gian con của $\mathbb{R}^n$ với $\dim U = m$ và $B = \{\mathbf{x}_1, \ldots, \mathbf{x}_m\}$ là một tập gồm *đúng* m vector trong U. Khi đó

$$B \text{ độc lập} \iff B \text{ sinh ra } U$$

Chứng minh. Giả sử B độc lập. Nếu B không sinh ra U thì, theo Định lý 5.2.6, B có thể mở rộng thành một cơ sở của U chứa *nhiều hơn* m vector. Điều này mâu thuẫn với Định lý bất biến vì $\dim U = m$. Vậy B sinh ra U.

Ngược lại, nếu B sinh ra U nhưng không độc lập, thì B có thể rút gọn thành một cơ sở của U chứa *ít hơn* m vector — lại mâu thuẫn. Vậy B độc lập. ■

Đây là định lý "tiết kiệm công sức" quan trọng nhất của chương

Định lý 5.2.7 nói: khi bạn *đã biết* $\dim U = m$ và có sẵn *đúng* m vector trong U, bạn chỉ cần chứng minh **một trong hai** tính chất (độc lập *hoặc* sinh), không cần cả hai. Trong bài tập, hãy luôn chọn tính chất dễ kiểm hơn — thường là tính *độc lập*, vì nó chỉ là giải một hệ thuần nhất hoặc tính một định thức.

Định lý 5.2.8

Cho $U \subseteq W$ là các không gian con của $\mathbb{R}^n$. Khi đó:

1. $\dim U \leq \dim W$.
2. Nếu $\dim U = \dim W$, thì $U = W$.

Chứng minh. Viết $\dim W = k$, và cho B là một cơ sở của U.

1. Nếu $\dim U > k$, thì B là một tập độc lập trong W chứa nhiều hơn k vector, mâu thuẫn Định lý cơ bản. Vậy $\dim U \leq k = \dim W$.

2. Nếu $\dim U = k$, thì B là tập độc lập trong W chứa $k = \dim W$ vector, nên B sinh ra W theo Định lý 5.2.7. Do đó $W = \operatorname{span} B = U$. ■

Từ Định lý 5.2.8 suy ra: nếu U là không gian con của $\mathbb{R}^n$ thì $\dim U$ là một trong các số nguyên $0, 1, 2, \ldots, n$, và:

$$\dim U = 0 \iff U = \{\mathbf{0}\}, \qquad \dim U = n \iff U = \mathbb{R}^n$$

Các không gian con còn lại của $\mathbb{R}^n$ được gọi là **thực sự** (proper). Ví dụ sau dùng Định lý 5.2.8 để chứng minh rằng các không gian con thực sự của $\mathbb{R}^2$ chính là các đường thẳng qua gốc, còn các không gian con thực sự của $\mathbb{R}^3$ là các đường thẳng và mặt phẳng qua gốc.

Ví dụ 5.2.14

1. Nếu U là không gian con của $\mathbb{R}^2$ hoặc $\mathbb{R}^3$, thì $\dim U = 1$ khi và chỉ khi U là một đường thẳng qua gốc tọa độ.

2. Nếu U là không gian con của $\mathbb{R}^3$, thì $\dim U = 2$ khi và chỉ khi U là một mặt phẳng qua gốc tọa độ.

Chứng minh.
(1) Vì $\dim U = 1$, lấy $\{\mathbf{u}\}$ là cơ sở của U. Khi đó $U = \operatorname{span}\{\mathbf{u}\} = \{t\mathbf{u} \mid t \in \mathbb{R}\}$, nên U là đường thẳng qua gốc với vector chỉ phương $\mathbf{u}$. Ngược lại, mỗi đường thẳng L với vector chỉ phương $\mathbf{d} \neq \mathbf{0}$ có dạng $L = \{t\mathbf{d} \mid t \in \mathbb{R}\}$. Vậy $\{\mathbf{d}\}$ là cơ sở của U, nên U có số chiều 1.
(2) Nếu $U \subseteq \mathbb{R}^3$ có số chiều 2, lấy $\{\mathbf{v}, \mathbf{w}\}$ là cơ sở của U. Khi đó $\mathbf{v}$ và $\mathbf{w}$ không song song (theo Ví dụ 5.2.7) nên $\mathbf{n} = \mathbf{v} \times \mathbf{w} \neq \mathbf{0}$. Đặt $P = \{\mathbf{x} \in \mathbb{R}^3 \mid \mathbf{n} \cdot \mathbf{x} = 0\}$ là mặt phẳng qua gốc với pháp tuyến $\mathbf{n}$. Khi đó P là không gian con của $\mathbb{R}^3$ (Ví dụ 5.1.1) và cả $\mathbf{v}$, $\mathbf{w}$ đều nằm trong P (chúng trực giao với $\mathbf{n}$), nên $U = \operatorname{span}\{\mathbf{v}, \mathbf{w}\} \subseteq P$ theo Định lý 5.1.1. Do đó

$$U \subseteq P \subseteq \mathbb{R}^3$$

Vì $\dim U = 2$ và $\dim(\mathbb{R}^3) = 3$, từ Định lý 5.2.8 suy ra $\dim P = 2$ hoặc 3, tức $P = U$ hoặc $P = \mathbb{R}^3$. Nhưng $P \neq \mathbb{R}^3$ (chẳng hạn $\mathbf{n}$ không nằm trong P), nên $U = P$ là một mặt phẳng qua gốc.
Ngược lại, nếu U là mặt phẳng qua gốc, thì $\dim U \in \{0, 1, 2, 3\}$ theo Định lý 5.2.8. Nhưng $\dim U \neq 0$ và $\neq 3$ vì $U \neq \{\mathbf{0}\}$ và $U \neq \mathbb{R}^3$, và $\dim U \neq 1$ theo phần (1). Vậy $\dim U = 2$. ■

Lưu ý chứng minh này cho thấy: nếu $\mathbf{v}$ và $\mathbf{w}$ khác không và không song song trong $\mathbb{R}^3$, thì $\operatorname{span}\{\mathbf{v}, \mathbf{w}\}$ chính là mặt phẳng có pháp tuyến $\mathbf{n} = \mathbf{v} \times \mathbf{w}$.

Tổng kết mục 5.2 — ba khái niệm phải phân biệt rõ

Khái niệm	Nghĩa	Kiểm tra thế nào
Sinh (span)	Đủ vector để dựng *mọi* phần tử của U	Giải $A\mathbf{x} = \mathbf{b}$ — có nghiệm với mọi $\mathbf{b}$?
Độc lập	*Không có vector thừa*	Giải $A\mathbf{x} = \mathbf{0}$ — chỉ có nghiệm $\mathbf{x} = \mathbf{0}$?
Cơ sở	Vừa đủ: sinh *và* độc lập	Cả hai điều trên (hoặc dùng Định lý 5.2.7 để chỉ kiểm một)

Hình dung: tập sinh có thể *quá nhiều* vector, tập độc lập có thể *quá ít*. Cơ sở là điểm cân bằng — và số vector ở điểm cân bằng đó chính là $\dim U$.

5.3 Tính trực giao

Độ dài và tính trực giao là các khái niệm cơ bản của hình học; trong $\mathbb{R}^2$ và $\mathbb{R}^3$ cả hai đều định nghĩa được qua tích vô hướng (dot product). Trong mục này ta mở rộng tích vô hướng cho vector trong $\mathbb{R}^n$, qua đó trang bị cho $\mathbb{R}^n$ hình học Euclid. Sau đó ta giới thiệu ý tưởng **cơ sở trực giao** — một trong những khái niệm hữu dụng nhất của đại số tuyến tính.

Tích vô hướng, độ dài và khoảng cách

Nếu $\mathbf{x} = (x_1, \ldots, x_n)$ và $\mathbf{y} = (y_1, \ldots, y_n)$ là hai bộ n số trong $\mathbb{R}^n$, nhắc lại tích vô hướng của chúng đã định nghĩa ở Mục 2.2:

$$\mathbf{x} \cdot \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$$

Chú ý nếu $\mathbf{x}$ và $\mathbf{y}$ viết dạng cột thì $\mathbf{x} \cdot \mathbf{y} = \mathbf{x}^T \mathbf{y}$ là một tích ma trận (và $\mathbf{x} \cdot \mathbf{y} = \mathbf{x}\mathbf{y}^T$ nếu viết dạng hàng). Ở đây $\mathbf{x} \cdot \mathbf{y}$ là ma trận 1×1, ta coi nó là một số.

Định nghĩa 5.6 — Độ dài trong $\mathbb{R}^n$

Như trong $\mathbb{R}^3$, **độ dài** (length, hay chuẩn — norm) $\|\mathbf{x}\|$ của vector $\mathbf{x}$ được định nghĩa bởi

$$\|\mathbf{x}\| = \sqrt{\mathbf{x} \cdot \mathbf{x}} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

trong đó $\sqrt{\cdot}$ chỉ căn bậc hai *dương*.

Một vector $\mathbf{x}$ có độ dài 1 được gọi là **vector đơn vị** (unit vector). Nếu $\mathbf{x} \neq \mathbf{0}$ thì $\|\mathbf{x}\| \neq 0$ và dễ thấy $\frac{1}{\|\mathbf{x}\|}\mathbf{x}$ là một vector đơn vị — ta sẽ dùng sự kiện này về sau.

Ví dụ 5.3.1

Nếu $\mathbf{x} = (1, -1, -3, 1)$ và $\mathbf{y} = (2, 1, 1, 0)$ trong $\mathbb{R}^4$, thì

$$\mathbf{x} \cdot \mathbf{y} = 2 - 1 - 3 + 0 = -2, \qquad \|\mathbf{x}\| = \sqrt{1 + 1 + 9 + 1} = \sqrt{12} = 2\sqrt{3}$$

Do đó $\frac{1}{2\sqrt{3}}\mathbf{x}$ là vector đơn vị; tương tự $\frac{1}{\sqrt{6}}\mathbf{y}$ cũng là vector đơn vị.

Các định nghĩa này khớp với $\mathbb{R}^2$ và $\mathbb{R}^3$, và nhiều tính chất được giữ nguyên trong $\mathbb{R}^n$:

Định lý 5.3.1

Cho $\mathbf{x}, \mathbf{y}, \mathbf{z}$ là các vector trong $\mathbb{R}^n$. Khi đó:

1. $\mathbf{x} \cdot \mathbf{y} = \mathbf{y} \cdot \mathbf{x}$.
2. $\mathbf{x} \cdot (\mathbf{y} + \mathbf{z}) = \mathbf{x} \cdot \mathbf{y} + \mathbf{x} \cdot \mathbf{z}$.
3. $(a\mathbf{x}) \cdot \mathbf{y} = a(\mathbf{x} \cdot \mathbf{y}) = \mathbf{x} \cdot (a\mathbf{y})$ với mọi vô hướng a.
4. $\|\mathbf{x}\|^2 = \mathbf{x} \cdot \mathbf{x}$.
5. $\|\mathbf{x}\| \geq 0$, và $\|\mathbf{x}\| = 0$ khi và chỉ khi $\mathbf{x} = \mathbf{0}$.
6. $\|a\mathbf{x}\| = |a|\,\|\mathbf{x}\|$ với mọi vô hướng a.

Chứng minh. (1), (2), (3) suy ra từ số học ma trận vì $\mathbf{x} \cdot \mathbf{y} = \mathbf{x}^T\mathbf{y}$; (4) hiển nhiên từ định nghĩa; (6) kiểm tra thường quy vì $|a| = \sqrt{a^2}$. Nếu $\mathbf{x} = (x_1, \ldots, x_n)$ thì $\|\mathbf{x}\| = \sqrt{x_1^2 + \cdots + x_n^2}$,

nên $\|\mathbf{x}\| = 0$ khi và chỉ khi $x_1^2 + \cdots + x_n^2 = 0$. Vì mỗi x_i là số thực, điều này xảy ra khi và chỉ khi $x_i = 0$ với mọi i, tức $\mathbf{x} = \mathbf{0}$. Đó là (5). ■

Nhờ Định lý 5.3.1, tính toán với tích vô hướng trong $\mathbb{R}^n$ giống hệt trong $\mathbb{R}^3$. Chẳng hạn

$$(3\mathbf{x} - 4\mathbf{y}) \cdot (7\mathbf{x} + 2\mathbf{y}) = 21\|\mathbf{x}\|^2 - 22(\mathbf{x} \cdot \mathbf{y}) - 8\|\mathbf{y}\|^2$$

đúng với mọi vector $\mathbf{x}$, $\mathbf{y}$.

Ví dụ 5.3.2

Chứng minh $\|\mathbf{x} + \mathbf{y}\|^2 = \|\mathbf{x}\|^2 + 2(\mathbf{x} \cdot \mathbf{y}) + \|\mathbf{y}\|^2$ với mọi $\mathbf{x}, \mathbf{y}$ trong $\mathbb{R}^n$.
Lời giải. Dùng Định lý 5.3.1 vài lần:

$$\|\mathbf{x} + \mathbf{y}\|^2 = (\mathbf{x} + \mathbf{y}) \cdot (\mathbf{x} + \mathbf{y}) = \mathbf{x} \cdot \mathbf{x} + \mathbf{x} \cdot \mathbf{y} + \mathbf{y} \cdot \mathbf{x} + \mathbf{y} \cdot \mathbf{y} = \|\mathbf{x}\|^2 + 2(\mathbf{x} \cdot \mathbf{y}) + \|\mathbf{y}\|^2$$

Ví dụ 5.3.3

Giả sử $\mathbb{R}^n = \operatorname{span}\{\mathbf{f}_1, \ldots, \mathbf{f}_k\}$. Nếu $\mathbf{x} \cdot \mathbf{f}_i = 0$ với mọi i, chứng minh $\mathbf{x} = \mathbf{0}$.
Lời giải. Ta chứng minh $\|\mathbf{x}\| = 0$ rồi dùng (5) của Định lý 5.3.1. Vì các $\mathbf{f}_i$ sinh ra $\mathbb{R}^n$, viết $\mathbf{x} = t_1\mathbf{f}_1 + \cdots + t_k\mathbf{f}_k$. Khi đó

$$\begin{aligned}\|\mathbf{x}\|^2 &= \mathbf{x} \cdot \mathbf{x} = \mathbf{x} \cdot (t_1\mathbf{f}_1 + \cdots + t_k\mathbf{f}_k) \\ &= t_1(\mathbf{x} \cdot \mathbf{f}_1) + \cdots + t_k(\mathbf{x} \cdot \mathbf{f}_k) = t_1(0) + \cdots + t_k(0) = 0\end{aligned}$$

Ở Mục 4.2 ta đã thấy nếu $\mathbf{u}, \mathbf{v}$ khác không trong $\mathbb{R}^3$ thì $\frac{\mathbf{u}\cdot\mathbf{v}}{\|\mathbf{u}\|\|\mathbf{v}\|} = \cos\theta$ với θ là góc giữa chúng. Vì $|\cos\theta| \le 1$, điều này cho $|\mathbf{u} \cdot \mathbf{v}| \le \|\mathbf{u}\|\|\mathbf{v}\|$. Dạng này đúng trong $\mathbb{R}^n$:

Định lý 5.3.2 — Bất đẳng thức Cauchy

Nếu $\mathbf{x}$ và $\mathbf{y}$ là vector trong $\mathbb{R}^n$, thì

$$|\mathbf{x} \cdot \mathbf{y}| \le \|\mathbf{x}\|\,\|\mathbf{y}\|$$

Hơn nữa $|\mathbf{x} \cdot \mathbf{y}| = \|\mathbf{x}\|\|\mathbf{y}\|$ khi và chỉ khi một trong hai vector là bội của vector kia.

Chứng minh. Bất đẳng thức đúng nếu $\mathbf{x} = \mathbf{0}$ hoặc $\mathbf{y} = \mathbf{0}$ (thực ra là đẳng thức). Ngược lại, đặt $\|\mathbf{x}\| = a > 0$ và $\|\mathbf{y}\| = b > 0$ cho tiện. Tính toán tương tự Ví dụ 5.3.2 cho

$$\|b\mathbf{x} - a\mathbf{y}\|^2 = 2ab(ab - \mathbf{x} \cdot \mathbf{y}) \quad \text{và} \quad \|b\mathbf{x} + a\mathbf{y}\|^2 = 2ab(ab + \mathbf{x} \cdot \mathbf{y}) \tag{5.1}$$

Suy ra $ab - \mathbf{x} \cdot \mathbf{y} \ge 0$ và $ab + \mathbf{x} \cdot \mathbf{y} \ge 0$, do đó $-ab \le \mathbf{x} \cdot \mathbf{y} \le ab$. Vậy $|\mathbf{x} \cdot \mathbf{y}| \le ab = \|\mathbf{x}\|\|\mathbf{y}\|$.

Nếu xảy ra đẳng thức thì $\mathbf{x} \cdot \mathbf{y} = ab$ hoặc $\mathbf{x} \cdot \mathbf{y} = -ab$. Khi đó phương trình (5.1) cho $b\mathbf{x} - a\mathbf{y} = \mathbf{0}$ hoặc $b\mathbf{x} + a\mathbf{y} = \mathbf{0}$, nên một vector là bội của vector kia. ■

Ghi chú lịch sử — Augustin Louis Cauchy (1789–1857)

Cauchy sinh ở Paris, trở thành giáo sư tại École Polytechnique năm 26 tuổi. Ông là một trong những nhà toán học vĩ đại nhất, công bố hơn 700 bài báo, và được nhớ đến nhiều nhất qua công trình về giải tích — nơi ông thiết lập những chuẩn mực mới về tính chặt chẽ và sáng lập lý thuyết hàm biến phức. Định lý 5.3.2 xuất hiện lần đầu trong hồi ký năm 1812 của ông về định thức.

Bất đẳng thức Cauchy tương đương với $(\mathbf{x} \cdot \mathbf{y})^2 \le \|\mathbf{x}\|^2\|\mathbf{y}\|^2$. Trong $\mathbb{R}^5$ nó trở thành

$$(x_1y_1 + x_2y_2 + x_3y_3 + x_4y_4 + x_5y_5)^2 \le (x_1^2 + \cdots + x_5^2)(y_1^2 + \cdots + y_5^2)$$

với mọi x_i, y_i trong $\mathbb{R}$.

Có một hệ quả quan trọng. Dùng Ví dụ 5.3.2 và $\mathbf{x}\cdot\mathbf{y} \le \|\mathbf{x}\|\|\mathbf{y}\|$:

$$\|\mathbf{x}+\mathbf{y}\|^2 = \|\mathbf{x}\|^2 + 2(\mathbf{x}\cdot\mathbf{y}) + \|\mathbf{y}\|^2 \le \|\mathbf{x}\|^2 + 2\|\mathbf{x}\|\|\mathbf{y}\| + \|\mathbf{y}\|^2 = (\|\mathbf{x}\| + \|\mathbf{y}\|)^2$$

Lấy căn bậc hai dương cho:

Hệ quả 5.3.1 — Bất đẳng thức tam giác

Nếu $\mathbf{x}$ và $\mathbf{y}$ là vector trong $\mathbb{R}^n$, thì $\|\mathbf{x}+\mathbf{y}\| \le \|\mathbf{x}\| + \|\mathbf{y}\|$.

Tên gọi xuất phát từ nhận xét: trong $\mathbb{R}^3$, bất đẳng thức này nói tổng độ dài hai cạnh của một tam giác không nhỏ hơn độ dài cạnh thứ ba.

Định nghĩa 5.7 — Khoảng cách trong $\mathbb{R}^n$

Nếu $\mathbf{x}$ và $\mathbf{y}$ là hai vector trong $\mathbb{R}^n$, ta định nghĩa **khoảng cách** $d(\mathbf{x},\mathbf{y})$ giữa chúng bởi

$$d(\mathbf{x},\mathbf{y}) = \|\mathbf{x}-\mathbf{y}\|$$

Định lý 5.3.3

Nếu $\mathbf{x}, \mathbf{y}, \mathbf{z}$ là ba vector trong $\mathbb{R}^n$:

1. $d(\mathbf{x},\mathbf{y}) \ge 0$ với mọi $\mathbf{x}, \mathbf{y}$.
2. $d(\mathbf{x},\mathbf{y}) = 0$ khi và chỉ khi $\mathbf{x} = \mathbf{y}$.
3. $d(\mathbf{x},\mathbf{y}) = d(\mathbf{y},\mathbf{x})$ với mọi $\mathbf{x}, \mathbf{y}$.
4. $d(\mathbf{x},\mathbf{z}) \le d(\mathbf{x},\mathbf{y}) + d(\mathbf{y},\mathbf{z})$ với mọi $\mathbf{x}, \mathbf{y}, \mathbf{z}$ (bất đẳng thức tam giác).

Chứng minh. (1) và (2) phát biểu lại phần (5) của Định lý 5.3.1 vì $d(\mathbf{x},\mathbf{y}) = \|\mathbf{x}-\mathbf{y}\|$, và (3) suy ra từ $\|\mathbf{u}\| = \|-\mathbf{u}\|$. Để chứng minh (4) dùng Hệ quả 5.3.1:

$$d(\mathbf{x},\mathbf{z}) = \|\mathbf{x}-\mathbf{z}\| = \|(\mathbf{x}-\mathbf{y}) + (\mathbf{y}-\mathbf{z})\| \le \|\mathbf{x}-\mathbf{y}\| + \|\mathbf{y}-\mathbf{z}\| = d(\mathbf{x},\mathbf{y}) + d(\mathbf{y},\mathbf{z}) \quad \blacksquare$$

Ghi chú cho người học — bốn tính chất này là định nghĩa của "không gian metric"

Bốn tính chất trong Định lý 5.3.3 không phải ngẫu nhiên: trong toán học hiện đại, *bất kỳ* hàm d nào thỏa bốn tính chất đó đều được gọi là một **metric** (khoảng cách), và tập kèm metric là một **không gian metric**.

Điều này rất quan trọng với ngành của bạn. Trong machine learning và bảo mật, người ta dùng nhiều loại metric khác nhau trên cùng một tập dữ liệu:

- **Euclidean** (L_2): $\sqrt{\sum (x_i - y_i)^2}$ — chính là cái trong mục này.
- **Manhattan** (L_1): $\sum |x_i - y_i|$ — dùng khi các chiều độc lập nhau.
- **Hamming**: số vị trí khác nhau — dùng cho chuỗi bit, so sánh hash, phát hiện lỗi truyền tin.
- **Cosine distance**: $1 - \frac{\mathbf{x}\cdot\mathbf{y}}{\|\mathbf{x}\|\|\mathbf{y}\|}$ — dùng cho embedding trong RAG và tìm kiếm ngữ nghĩa (chú ý: cái này *không* thỏa bất đẳng thức tam giác, nên nghiêm ngặt mà nói nó không phải metric).

Bất đẳng thức Cauchy chính là thứ bảo đảm cosine similarity luôn nằm trong $[-1, 1]$ — nếu không có nó, khái niệm "độ tương đồng 0.87" sẽ vô nghĩa.

Tập trực giao và Định lý khai triển

Định nghĩa 5.8 — Tập trực giao và trực chuẩn

Ta nói hai vector $\mathbf{x}$ và $\mathbf{y}$ trong $\mathbb{R}^n$ **trực giao** (orthogonal) nếu $\mathbf{x}\cdot\mathbf{y}=0$. Tổng quát hơn, một tập $\{\mathbf{x}_1,\dots,\mathbf{x}_k\}$ các vector trong $\mathbb{R}^n$ gọi là **tập trực giao** (orthogonal set) nếu

$$\mathbf{x}_i\cdot\mathbf{x}_j=0 \text{ với mọi } i\neq j, \quad \text{và} \quad \mathbf{x}_i\neq\mathbf{0} \text{ với mọi } i$$

Chú ý $\{\mathbf{x}\}$ là tập trực giao nếu $\mathbf{x}\neq\mathbf{0}$. Một tập $\{\mathbf{x}_1,\dots,\mathbf{x}_k\}$ gọi là **trực chuẩn** (orthonormal) nếu nó trực giao *và* mỗi $\mathbf{x}_i$ là vector đơn vị:

$$\|\mathbf{x}_i\|=1 \text{ với mọi } i$$

Ví dụ 5.3.4

Cơ sở chuẩn tắc $\{\mathbf{e}_1,\mathbf{e}_2,\dots,\mathbf{e}_n\}$ là một tập trực chuẩn trong $\mathbb{R}^n$.

Ví dụ 5.3.5

Nếu $\{\mathbf{x}_1,\dots,\mathbf{x}_k\}$ trực giao, thì $\{a_1\mathbf{x}_1,a_2\mathbf{x}_2,\dots,a_k\mathbf{x}_k\}$ cũng trực giao, với mọi vô hướng $a_i\neq0$.

Định nghĩa 5.9 — Chuẩn hóa một tập trực giao

Nếu $\{\mathbf{x}_1,\dots,\mathbf{x}_k\}$ là tập trực giao, thì

$$\left\{\frac{1}{\|\mathbf{x}_1\|}\mathbf{x}_1,\ \frac{1}{\|\mathbf{x}_2\|}\mathbf{x}_2,\ \dots,\ \frac{1}{\|\mathbf{x}_k\|}\mathbf{x}_k\right\}$$

là một tập *trực chuẩn*, và ta nói nó là kết quả của việc **chuẩn hóa** (normalizing) tập trực giao $\{\mathbf{x}_1,\dots,\mathbf{x}_k\}$.

Ví dụ 5.3.6

Nếu

$$\mathbf{f}_1=\begin{bmatrix}1\\1\\1\\-1\end{bmatrix},\quad \mathbf{f}_2=\begin{bmatrix}1\\0\\1\\2\end{bmatrix},\quad \mathbf{f}_3=\begin{bmatrix}-1\\0\\1\\0\end{bmatrix},\quad \mathbf{f}_4=\begin{bmatrix}-1\\3\\-1\\1\end{bmatrix}$$

thì $\{\mathbf{f}_1,\mathbf{f}_2,\mathbf{f}_3,\mathbf{f}_4\}$ là tập trực giao trong $\mathbb{R}^4$ (dễ kiểm tra). Sau khi chuẩn hóa, tập trực chuẩn tương ứng là

$$\left\{\tfrac{1}{2}\mathbf{f}_1,\ \tfrac{1}{\sqrt{6}}\mathbf{f}_2,\ \tfrac{1}{\sqrt{2}}\mathbf{f}_3,\ \tfrac{1}{2\sqrt{3}}\mathbf{f}_4\right\}$$

Kết quả quan trọng nhất về tính trực giao là định lý Pythagoras. Với hai vector trực giao $\mathbf{v},\mathbf{w}$ trong $\mathbb{R}^3$, nó khẳng định $\|\mathbf{v}+\mathbf{w}\|^2=\|\mathbf{v}\|^2+\|\mathbf{w}\|^2$. Dạng này đúng cho *mọi* tập trực giao trong $\mathbb{R}^n$.

[2] Lý do buộc tập trực giao gồm các vector khác không là vì ta chủ yếu quan tâm tới *cơ sở* trực giao.

Định lý 5.3.4 — Định lý Pythagoras

Nếu $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_k\}$ là tập trực giao trong $\mathbb{R}^n$, thì

$$\|\mathbf{x}_1 + \mathbf{x}_2 + \cdots + \mathbf{x}_k\|^2 = \|\mathbf{x}_1\|^2 + \|\mathbf{x}_2\|^2 + \cdots + \|\mathbf{x}_k\|^2$$

Chứng minh. Vì $\mathbf{x}_i \cdot \mathbf{x}_j = 0$ khi $i \neq j$:

$$\begin{aligned}\|\mathbf{x}_1 + \cdots + \mathbf{x}_k\|^2 &= (\mathbf{x}_1 + \cdots + \mathbf{x}_k) \cdot (\mathbf{x}_1 + \cdots + \mathbf{x}_k) \\ &= (\mathbf{x}_1 \cdot \mathbf{x}_1 + \cdots + \mathbf{x}_k \cdot \mathbf{x}_k) + \sum_{i \neq j} \mathbf{x}_i \cdot \mathbf{x}_j \\ &= \|\mathbf{x}_1\|^2 + \cdots + \|\mathbf{x}_k\|^2 + 0 \quad \blacksquare\end{aligned}$$

Nếu **v** và **w** trực giao và khác không trong $\mathbb{R}^3$ thì chắc chắn chúng không song song, nên độc lập tuyến tính theo Ví dụ 5.2.7. Định lý sau mở rộng nhận xét này rất xa:

Định lý 5.3.5

Mọi tập trực giao trong $\mathbb{R}^n$ đều độc lập tuyến tính.

Chứng minh. Cho $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ trực giao và giả sử một tổ hợp triệt tiêu: $t_1\mathbf{x}_1 + \cdots + t_k\mathbf{x}_k = \mathbf{0}$. Khi đó

$$\begin{aligned}0 = \mathbf{x}_1 \cdot \mathbf{0} &= \mathbf{x}_1 \cdot (t_1\mathbf{x}_1 + t_2\mathbf{x}_2 + \cdots + t_k\mathbf{x}_k) \\ &= t_1(\mathbf{x}_1 \cdot \mathbf{x}_1) + t_2(\mathbf{x}_1 \cdot \mathbf{x}_2) + \cdots + t_k(\mathbf{x}_1 \cdot \mathbf{x}_k) \\ &= t_1\|\mathbf{x}_1\|^2 + t_2(0) + \cdots + t_k(0) = t_1\|\mathbf{x}_1\|^2\end{aligned}$$

Vì $\|\mathbf{x}_1\|^2 \neq 0$, suy ra $t_1 = 0$. Tương tự $t_i = 0$ với mọi i. $\blacksquare$

Định lý 5.3.5 gợi ý xét các **cơ sở trực giao** của $\mathbb{R}^n$, tức các tập trực giao sinh ra $\mathbb{R}^n$. Chúng hóa ra là những cơ sở *tốt nhất*, theo nghĩa: khi khai triển một vector thành tổ hợp tuyến tính của các vector cơ sở, ta có *công thức tường minh* cho các hệ số.

Định lý 5.3.6 — Định lý khai triển (Expansion Theorem)

Cho $\{\mathbf{f}_1, \mathbf{f}_2, \ldots, \mathbf{f}_m\}$ là một cơ sở trực giao của không gian con U của $\mathbb{R}^n$. Nếu $\mathbf{x}$ là vector bất kỳ trong U, thì

$$\mathbf{x} = \left(\frac{\mathbf{x} \cdot \mathbf{f}_1}{\|\mathbf{f}_1\|^2}\right)\mathbf{f}_1 + \left(\frac{\mathbf{x} \cdot \mathbf{f}_2}{\|\mathbf{f}_2\|^2}\right)\mathbf{f}_2 + \cdots + \left(\frac{\mathbf{x} \cdot \mathbf{f}_m}{\|\mathbf{f}_m\|^2}\right)\mathbf{f}_m$$

Chứng minh. Vì $\{\mathbf{f}_1, \ldots, \mathbf{f}_m\}$ sinh ra U, ta có $\mathbf{x} = t_1\mathbf{f}_1 + \cdots + t_m\mathbf{f}_m$ với t_i là vô hướng. Để tìm t_1 ta lấy tích vô hướng hai vế với $\mathbf{f}_1$:

$$\begin{aligned}\mathbf{x} \cdot \mathbf{f}_1 &= (t_1\mathbf{f}_1 + t_2\mathbf{f}_2 + \cdots + t_m\mathbf{f}_m) \cdot \mathbf{f}_1 \\ &= t_1(\mathbf{f}_1 \cdot \mathbf{f}_1) + t_2(\mathbf{f}_2 \cdot \mathbf{f}_1) + \cdots + t_m(\mathbf{f}_m \cdot \mathbf{f}_1) \\ &= t_1\|\mathbf{f}_1\|^2 + t_2(0) + \cdots + t_m(0) = t_1\|\mathbf{f}_1\|^2\end{aligned}$$

Vì $\mathbf{f}_1 \neq \mathbf{0}$, ta được $t_1 = \dfrac{\mathbf{x} \cdot \mathbf{f}_1}{\|\mathbf{f}_1\|^2}$. Tương tự $t_i = \dfrac{\mathbf{x} \cdot \mathbf{f}_i}{\|\mathbf{f}_i\|^2}$ với mọi i. $\blacksquare$

Khai triển trong Định lý 5.3.6 được gọi là **khai triển Fourier** của $\mathbf{x}$, và các hệ số $t_i = \frac{\mathbf{x} \cdot \mathbf{f}_i}{\|\mathbf{f}_i\|^2}$ gọi là **hệ số Fourier**. Chú ý nếu $\{\mathbf{f}_1, \ldots, \mathbf{f}_m\}$ thực sự *trực chuẩn*, thì đơn giản $t_i = \mathbf{x} \cdot \mathbf{f}_i$.

Ví dụ 5.3.7

Khai triển $\mathbf{x} = (a, b, c, d)$ thành tổ hợp tuyến tính của cơ sở trực giao $\{\mathbf{f}_1, \mathbf{f}_2, \mathbf{f}_3, \mathbf{f}_4\}$ của $\mathbb{R}^4$ cho ở Ví dụ 5.3.6.

Lời giải. Ta có $\mathbf{f}_1 = (1, 1, 1, -1)$, $\mathbf{f}_2 = (1, 0, 1, 2)$, $\mathbf{f}_3 = (-1, 0, 1, 0)$, $\mathbf{f}_4 = (-1, 3, -1, 1)$, nên các hệ số Fourier là

$$t_1 = \frac{\mathbf{x} \cdot \mathbf{f}_1}{\|\mathbf{f}_1\|^2} = \tfrac{1}{4}(a + b + c - d) \quad t_3 = \frac{\mathbf{x} \cdot \mathbf{f}_3}{\|\mathbf{f}_3\|^2} = \tfrac{1}{2}(-a + c)$$

$$t_2 = \frac{\mathbf{x} \cdot \mathbf{f}_2}{\|\mathbf{f}_2\|^2} = \tfrac{1}{6}(a + c + 2d) \qquad t_4 = \frac{\mathbf{x} \cdot \mathbf{f}_4}{\|\mathbf{f}_4\|^2} = \tfrac{1}{12}(-a + 3b - c + d)$$

Bạn đọc có thể kiểm tra rằng quả thực $\mathbf{x} = t_1\mathbf{f}_1 + t_2\mathbf{f}_2 + t_3\mathbf{f}_3 + t_4\mathbf{f}_4$.

Một câu hỏi tự nhiên nảy sinh: *Mọi* không gian con U của $\mathbb{R}^n$ đều có cơ sở trực giao chứ? Câu trả lời là **có**; thực tế còn có một quy trình hệ thống, gọi là **thuật toán Gram–Schmidt**, để biến *bất kỳ* cơ sở nào của U thành cơ sở trực giao. Điều này dẫn tới định nghĩa phép chiếu lên không gian con U, tổng quát hóa phép chiếu lên một vector dùng trong $\mathbb{R}^2$ và $\mathbb{R}^3$. Tất cả được bàn ở Mục 8.1.

Ghi chú cho người học — vì sao cơ sở trực giao là "cơ sở tốt nhất"

Đây là điểm cần hiểu thật rõ, vì nó là lý do trực giao có mặt ở khắp nơi trong kỹ thuật.
Với cơ sở bất kỳ: để tìm tọa độ của $\mathbf{x}$, bạn phải *giải một hệ phương trình* $A\mathbf{t} = \mathbf{x}$ — tốn $O(n^3)$ và có thể mất ổn định số học nếu các vector cơ sở "gần song song".
Với cơ sở trực giao: mỗi tọa độ tính *độc lập* bằng một tích vô hướng, $t_i = \frac{\mathbf{x} \cdot \mathbf{f}_i}{\|\mathbf{f}_i\|^2}$ — tổng cộng $O(n^2)$, song song hóa được hoàn toàn, và không có vấn đề ổn định số.
Hệ quả trong thực tế:

- **Nén ảnh JPEG** dùng DCT — một cơ sở trực giao của không gian khối 8×8 pixel. Nén = giữ lại vài hệ số Fourier lớn, vứt phần còn lại.
- **MP3, xử lý tín hiệu** dùng khai triển Fourier — đúng định lý 5.3.6, chỉ là trong không gian vô hạn chiều.
- **PCA trong machine learning** tìm một cơ sở trực chuẩn sao cho vài tọa độ đầu giữ được nhiều phương sai nhất.
- **Mã hóa / mã sửa lỗi**: các hàng trực giao trong ma trận sinh cho phép giải mã từng bit độc lập.

Ghi nhớ một câu: *trực giao biến bài toán giải hệ thành bài toán tính tích vô hướng*.

5.4 Hạng của ma trận

Trong mục này ta dùng khái niệm số chiều để làm rõ định nghĩa **hạng** (rank) của ma trận đã nêu ở Mục 1.2, và nghiên cứu các tính chất của nó. Việc này đòi hỏi xử lý hàng và cột một cách đồng đẳng. Tuy thói quen của ta là viết bộ n số trong $\mathbb{R}^n$ dạng *cột*, trong mục này ta sẽ thường viết dạng *hàng*.

Định nghĩa 5.10 — Không gian cột và không gian hàng của ma trận

Cho A là ma trận $m \times n$.

- **Không gian cột** (column space) $\operatorname{col} A$ là không gian con của $\mathbb{R}^m$ sinh bởi các *cột* của A.
- **Không gian hàng** (row space) $\operatorname{row} A$ là không gian con của $\mathbb{R}^n$ sinh bởi các *hàng* của A.

Bổ đề 5.4.1

Cho A và B là các ma trận $m \times n$.

1. Nếu $A \to B$ bằng các phép biến đổi sơ cấp trên *hàng*, thì $\operatorname{row} A = \operatorname{row} B$.
2. Nếu $A \to B$ bằng các phép biến đổi sơ cấp trên *cột*, thì $\operatorname{col} A = \operatorname{col} B$.

Chứng minh. Ta chứng minh (1); (2) tương tự. Chỉ cần xét trường hợp $A \to B$ bằng *một* phép biến đổi hàng. Gọi $R_1, R_2, \ldots, R_m$ là các hàng của A. Phép biến đổi $A \to B$ hoặc đổi chỗ hai hàng, hoặc nhân một hàng với hằng số khác không, hoặc cộng bội của một hàng vào hàng khác. Hai trường hợp đầu dành cho bạn đọc. Trường hợp cuối, giả sử a lần hàng p được cộng vào hàng q ($p < q$). Khi đó các hàng của B là $R_1, \ldots, R_p, \ldots, R_q + aR_p, \ldots, R_m$, và Định lý 5.1.1 cho

$$\operatorname{span}\{R_1, \ldots, R_p, \ldots, R_q, \ldots, R_m\} = \operatorname{span}\{R_1, \ldots, R_p, \ldots, R_q + aR_p, \ldots, R_m\}$$

Tức là $\operatorname{row} A = \operatorname{row} B$. ■

Với ma trận A bất kỳ, ta luôn đưa được $A \to R$ bằng phép biến đổi hàng, trong đó R là ma trận bậc thang dòng. Do đó $\operatorname{row} A = \operatorname{row} R$ theo Bổ đề 5.4.1; nên phần đầu của kết quả sau rất đáng chú ý.

Bổ đề 5.4.2

Nếu R là ma trận bậc thang dòng, thì

1. Các *hàng khác không* của R là một cơ sở của $\operatorname{row} R$.
2. Các *cột chứa số 1 dẫn đầu* của R là một cơ sở của $\operatorname{col} R$.

Chứng minh. Các hàng của R độc lập theo Ví dụ 5.2.6, và chúng sinh ra $\operatorname{row} R$ theo định nghĩa. Đó là (1).

Gọi $\mathbf{c}_{j_1}, \mathbf{c}_{j_2}, \ldots, \mathbf{c}_{j_r}$ là các cột của R chứa số 1 dẫn đầu. Khi đó $\{\mathbf{c}_{j_1}, \ldots, \mathbf{c}_{j_r}\}$ độc lập vì các số 1 dẫn đầu nằm ở các hàng khác nhau (và có số 0 ở dưới cũng như bên trái chúng). Gọi U là không gian con gồm mọi cột trong $\mathbb{R}^m$ có $m - r$ thành phần cuối bằng 0. Khi đó $\dim U = r$ (nó chính là $\mathbb{R}^r$ thêm các số 0). Vậy tập độc lập $\{\mathbf{c}_{j_1}, \ldots, \mathbf{c}_{j_r}\}$ là cơ sở của U theo Định lý 5.2.7. Vì mỗi $\mathbf{c}_{j_i}$ nằm trong $\operatorname{col} R$, suy ra $\operatorname{col} R = U$, chứng minh (2). ■

Với Bổ đề 5.4.2 ta có thể lấp một khoảng trống trong định nghĩa hạng ở Chương 1. Cho A là ma trận bất kỳ và giả sử A được đưa về một ma trận bậc thang dòng R. Chú ý *R không duy nhất*. Ở Mục 1.2 ta định nghĩa $\operatorname{rank} A$ là số số 1 dẫn đầu trong R, tức số hàng khác không của R. Việc số này *không phụ thuộc* vào lựa chọn R đã chưa được chứng minh ở Mục 1.2. Tuy nhiên phần (1) của Bổ đề 5.4.2 cho thấy

$$\boxed{\operatorname{rank} A = \dim(\operatorname{row} A)}$$

và do đó $\operatorname{rank} A$ độc lập với R.

Ví dụ 5.4.1

Tìm một cơ sở của $U = \text{span}\{(1,1,2,3),\ (2,4,1,0),\ (1,5,-4,-9)\}$.

Lời giải. U là không gian hàng của $\begin{bmatrix} 1 & 1 & 2 & 3 \\ 2 & 4 & 1 & 0 \\ 1 & 5 & -4 & -9 \end{bmatrix}$. Ma trận này có dạng bậc thang dòng

$$\begin{bmatrix} 1 & 1 & 2 & 3 \\ 0 & 1 & -\frac{3}{2} & -3 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

nên $\{(1,1,2,3),\ (0,1,-\frac{3}{2},-3)\}$ là cơ sở của U theo Bổ đề 5.4.2. Chú ý $\{(1,1,2,3),\ (0,2,-3,-6)\}$ là một cơ sở khác, tránh được phân số.

Bổ đề 5.4.1 và 5.4.2 đủ để chứng minh định lý nền tảng sau.

Định lý 5.4.1 — Định lý về hạng (Rank Theorem)

Cho A là ma trận $m \times n$ bất kỳ có hạng r. Khi đó

$$\dim(\text{col}\, A) = \dim(\text{row}\, A) = r$$

Hơn nữa, nếu A được đưa về ma trận bậc thang dòng R bằng các phép biến đổi hàng, thì

1. r hàng khác không của R là một cơ sở của $\text{row}\, A$.
2. Nếu các số 1 dẫn đầu nằm ở các cột $j_1, j_2, \ldots, j_r$ của R, thì các cột $j_1, j_2, \ldots, j_r$ **của** A (không phải của R!) là một cơ sở của $\text{col}\, A$.

Chứng minh. Ta có $\text{row}\, A = \text{row}\, R$ theo Bổ đề 5.4.1, nên (1) suy ra từ Bổ đề 5.4.2. Hơn nữa $R = UA$ với U là ma trận khả nghịch nào đó (Định lý 2.5.1). Viết $A = [\,\mathbf{c}_1\ \mathbf{c}_2\ \cdots\ \mathbf{c}_n\,]$. Khi đó

$$R = UA = U[\,\mathbf{c}_1\ \cdots\ \mathbf{c}_n\,] = [\,U\mathbf{c}_1\ \cdots\ U\mathbf{c}_n\,]$$

Vậy, theo ký hiệu ở (2), tập $B = \{U\mathbf{c}_{j_1}, \ldots, U\mathbf{c}_{j_r}\}$ là cơ sở của $\text{col}\, R$ theo Bổ đề 5.4.2. Để chứng minh (2) và $\dim(\text{col}\, A) = r$, chỉ cần chứng minh $D = \{\mathbf{c}_{j_1}, \ldots, \mathbf{c}_{j_r}\}$ là cơ sở của $\text{col}\, A$. Trước hết, D độc lập tuyến tính vì U khả nghịch. Tiếp theo ta chứng minh mọi cột $\mathbf{c}_j$ là tổ hợp tuyến tính của các $\mathbf{c}_{j_i}$. Thật vậy, $U\mathbf{c}_j$ là cột j của R, nên là tổ hợp tuyến tính của các $U\mathbf{c}_{j_i}$:

$$U\mathbf{c}_j = a_1 U\mathbf{c}_{j_1} + a_2 U\mathbf{c}_{j_2} + \cdots + a_r U\mathbf{c}_{j_r}$$

Vì U khả nghịch, suy ra $\mathbf{c}_j = a_1\mathbf{c}_{j_1} + \cdots + a_r\mathbf{c}_{j_r}$, và chứng minh hoàn tất. ■

Lỗi sai phổ biến nhất của cả mục 5.4

Đọc kỹ phần (2) của Định lý 5.4.1: cơ sở của $\text{col}\, A$ gồm các cột **của** A, chứ *không phải* các cột của ma trận bậc thang R.
Lý do: phép biến đổi *hàng* **bảo toàn không gian hàng** nhưng **làm thay đổi không gian cột**. Nó chỉ giữ nguyên *quan hệ phụ thuộc* giữa các cột — đó là lý do ta dùng R để *xác định cột nào* nằm trong cơ sở, rồi quay về A để *lấy các cột đó*.
Cách nhớ: *dùng R để chỉ điểm, dùng A để lấy hàng hóa.*

Ví dụ 5.4.2

Tính hạng của $A = \begin{bmatrix} 1 & 2 & 2 & -1 \\ 3 & 6 & 5 & 0 \\ 1 & 2 & 1 & 2 \end{bmatrix}$ và tìm cơ sở của row A và col A.

Lời giải. Rút gọn A về dạng bậc thang dòng:

$$\begin{bmatrix} 1 & 2 & 2 & -1 \\ 3 & 6 & 5 & 0 \\ 1 & 2 & 1 & 2 \end{bmatrix} \to \begin{bmatrix} 1 & 2 & 2 & -1 \\ 0 & 0 & -1 & 3 \\ 0 & 0 & -1 & 3 \end{bmatrix} \to \begin{bmatrix} 1 & 2 & 2 & -1 \\ 0 & 0 & -1 & 3 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

Vậy $\operatorname{rank} A = 2$, và $\{[1\,2\,2\,-1],\ [0\,0\,1\,-3]\}$ là cơ sở của row A.
Vì các số 1 dẫn đầu nằm ở cột 1 và cột 3 của ma trận bậc thang, Định lý 5.4.1 cho thấy cột 1 và cột 3 *của* A là một cơ sở của col A:

$$\left\{ \begin{bmatrix} 1 \\ 3 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ 5 \\ 1 \end{bmatrix} \right\}$$

Định lý 5.4.1 có nhiều hệ quả quan trọng.

Hệ quả 5.4.1

Với ma trận A bất kỳ, $\operatorname{rank} A = \operatorname{rank}(A^T)$.

Hệ quả 5.4.2

Nếu A là ma trận $m \times n$, thì $\operatorname{rank} A \le m$ và $\operatorname{rank} A \le n$.

Hệ quả 5.4.3

$\operatorname{rank} A = \operatorname{rank}(UA) = \operatorname{rank}(AV)$ với mọi U, V khả nghịch.

Chứng minh. Bổ đề 5.4.1 cho $\operatorname{rank} A = \operatorname{rank}(UA)$. Dùng điều này và Hệ quả 5.4.1:

$$\operatorname{rank}(AV) = \operatorname{rank}\left((AV)^T\right) = \operatorname{rank}(V^T A^T) = \operatorname{rank}(A^T) = \operatorname{rank} A \quad \blacksquare$$

Bổ đề 5.4.3

Cho A, U, V là các ma trận cỡ $m \times n$, $p \times m$, $n \times q$ tương ứng.

1. $\operatorname{col}(AV) \subseteq \operatorname{col} A$, với dấu bằng nếu $VV' = I_n$ với V' nào đó.
2. $\operatorname{row}(UA) \subseteq \operatorname{row} A$, với dấu bằng nếu $U'U = I_m$ với U' nào đó.

Chứng minh. Với (1), viết $V = [\mathbf{v}_1\ \mathbf{v}_2\ \cdots\ \mathbf{v}_q]$. Khi đó $AV = [A\mathbf{v}_1\ \cdots\ A\mathbf{v}_q]$, và mỗi $A\mathbf{v}_j$ nằm trong $\operatorname{col} A$ theo Định nghĩa 2.4. Suy ra $\operatorname{col}(AV) \subseteq \operatorname{col} A$. Nếu $VV' = I_n$, ta được $\operatorname{col} A = \operatorname{col}[(AV)V'] \subseteq \operatorname{col}(AV)$ theo cách tương tự.

Với (2), ta có $\operatorname{col}\left((UA)^T\right) = \operatorname{col}(A^T U^T) \subseteq \operatorname{col}(A^T)$ theo (1), từ đó $\operatorname{row}(UA) \subseteq \operatorname{row} A$. $\blacksquare$

Hệ quả 5.4.4

Nếu A là $m \times n$ và B là $n \times m$, thì $\operatorname{rank} AB \leq \operatorname{rank} A$ và $\operatorname{rank} AB \leq \operatorname{rank} B$.

Hạng, số khuyết và Định lý Rank–Nullity

Ở Mục 5.1 ta đã bàn hai không gian con khác gắn với ma trận A cỡ $m \times n$: **không gian nghiệm** (null space) $\text{null}(A)$ và **không gian ảnh** (image space) $\text{im}(A)$:

$$\text{null}(A) = \{\mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} = \mathbf{0}\}, \qquad \text{im}(A) = \{A\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n\}$$

Định nghĩa 5.11 — Số khuyết (Nullity)

Số chiều của không gian nghiệm của một ma trận được gọi là **số khuyết** (nullity), ký hiệu $\dim[\text{null}(A)]$.

Nhắc lại $\text{im}(A) = \text{col}(A)$ theo Ví dụ 5.1.8. Nên nếu A có hạng r thì $\dim[\text{im}(A)] = \dim[\text{col}(A)] = r$.

Định lý 5.4.2 — Hạng và số khuyết (Rank–Nullity)

Cho A là ma trận $m \times n$ có hạng r. Khi đó

1. $\text{rank}(A) + \dim[\text{null}(A)] = n$.
2. $n - r$ nghiệm cơ bản của hệ $A\mathbf{x} = \mathbf{0}$ do thuật toán Gauss cung cấp là một cơ sở của $\text{null}(A)$, nên $\dim[\text{null}(A)] = n - r$.
3. Định lý 5.4.1 cung cấp một cơ sở của $\text{im}(A) = \text{col}(A)$, và $\dim[\text{im}(A)] = r$.

Chứng minh. Phần (1) suy ra từ (2), nên chỉ cần chứng minh (2). Ta đã biết (Định lý 2.2.1) rằng $\text{null}(A)$ được sinh bởi $n - r$ nghiệm cơ bản của $A\mathbf{x} = \mathbf{0}$. Dùng Định lý 5.2.7, chỉ cần chứng minh $\dim[\text{null}(A)] = n - r$. Cho $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ là cơ sở của $\text{null}(A)$, mở rộng thành cơ sở $\{\mathbf{x}_1, \ldots, \mathbf{x}_k, \mathbf{x}_{k+1}, \ldots, \mathbf{x}_n\}$ của $\mathbb{R}^n$ (Định lý 5.2.6). Chỉ cần chứng minh $\{A\mathbf{x}_{k+1}, \ldots, A\mathbf{x}_n\}$ là cơ sở của $\text{im}(A)$; khi đó $n - k = r$ nên $k = n - r$ như yêu cầu.

Tính sinh. Lấy $A\mathbf{x}$ trong $\text{im}(A)$, viết $\mathbf{x} = a_1\mathbf{x}_1 + \cdots + a_k\mathbf{x}_k + a_{k+1}\mathbf{x}_{k+1} + \cdots + a_n\mathbf{x}_n$. Khi đó $A\mathbf{x} = a_{k+1}A\mathbf{x}_{k+1} + \cdots + a_nA\mathbf{x}_n$ vì $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\} \subseteq \text{null}(A)$.

Tính độc lập. Cho $t_{k+1}A\mathbf{x}_{k+1} + \cdots + t_nA\mathbf{x}_n = \mathbf{0}$. Khi đó $t_{k+1}\mathbf{x}_{k+1} + \cdots + t_n\mathbf{x}_n$ nằm trong $\text{null}\,A$, nên bằng $t_1\mathbf{x}_1 + \cdots + t_k\mathbf{x}_k$ với $t_1, \ldots, t_k$ nào đó. Nhưng tính độc lập của các $\mathbf{x}_i$ cho $t_i = 0$ với mọi i. ■

Ví dụ 5.4.3

Nếu $A = \begin{bmatrix} 1 & -2 & 1 & 1 \\ -1 & 2 & 0 & 1 \\ 2 & -4 & 1 & 0 \end{bmatrix}$, tìm cơ sở của $\text{null}(A)$ và $\text{im}(A)$, từ đó tìm số chiều của chúng.

Lời giải. Nếu $\mathbf{x}$ nằm trong $\text{null}(A)$ thì $A\mathbf{x} = \mathbf{0}$, nên ta giải hệ $A\mathbf{x} = \mathbf{0}$. Rút gọn ma trận mở rộng về dạng rút gọn:

$$\left[\begin{array}{cccc|c} 1 & -2 & 1 & 1 & 0 \\ -1 & 2 & 0 & 1 & 0 \\ 2 & -4 & 1 & 0 & 0 \end{array}\right] \to \left[\begin{array}{cccc|c} 1 & -2 & 0 & -1 & 0 \\ 0 & 0 & 1 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{array}\right]$$

Vậy $r = \text{rank}(A) = 2$. Ở đây $\text{im}(A) = \text{col}(A)$ có cơ sở $\left\{ \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}$ theo Định lý 5.4.1, vì các số 1 dẫn đầu nằm ở cột 1 và 3. Đặc biệt $\dim[\text{im}(A)] = 2 = r$.
Với $\text{null}(A)$, ta dùng khử Gauss. Các biến dẫn đầu là x_1 và x_3, nên các biến không dẫn đầu thành tham số: $x_2 = s$, $x_4 = t$. Từ ma trận rút gọn: $x_1 = 2s + t$ và $x_3 = -2t$, nên nghiệm tổng quát là

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 2s+t \\ s \\ -2t \\ t \end{bmatrix} = s\mathbf{x}_1 + t\mathbf{x}_2, \quad \mathbf{x}_1 = \begin{bmatrix} 2 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \ \mathbf{x}_2 = \begin{bmatrix} 1 \\ 0 \\ -2 \\ 1 \end{bmatrix}$$

Do đó $\text{null}(A) = \text{span}\{\mathbf{x}_1, \mathbf{x}_2\}$. Định lý 5.4.2 khẳng định $\{\mathbf{x}_1, \mathbf{x}_2\}$ là một *cơ sở* của $\text{null}(A)$. Đặc biệt $\dim[\text{null}(A)] = 2 = n - r$ (ở đây $n = 4$, $r = 2$), đúng như Định lý 5.4.2 khẳng định.

Ghi chú cho người học — Rank–Nullity là "định luật bảo toàn" của đại số tuyến tính

Công thức $\text{rank}(A) + \dim[\text{null}(A)] = n$ nên được đọc như một *định luật bảo toàn thông tin*:
Ma trận A nhận đầu vào n chiều. Mỗi chiều đầu vào hoặc *sống sót* qua phép biến đổi (đóng góp vào rank — tức vào ảnh), hoặc *bị nghiền về 0* (đóng góp vào null). Không có chiều nào biến mất vô cớ, và tổng luôn bằng n.
Chú ý m (số hàng) *không* xuất hiện trong công thức — điều này gây bất ngờ cho người mới nhưng hoàn toàn hợp lý: n là số chiều *đầu vào*, và ta đang phân loại các chiều đầu vào.
Ứng dụng trực tiếp trong ngành của bạn:

- **Hàm băm / nén dữ liệu:** nullity lớn nghĩa là nhiều đầu vào khác nhau cho cùng đầu ra — chính là *collision*. Với biến đổi tuyến tính trên $\mathbb{F}_2$ (như một số hàm băm đơn giản hoặc mã sửa lỗi), số collision cho mỗi đầu ra đúng bằng $2^{\dim \text{null}}$.
- **Mã sửa lỗi tuyến tính:** không gian mã là null của ma trận kiểm tra chẵn lẻ H; Rank–Nullity cho ngay số từ mã hợp lệ.
- **Machine learning:** nếu ma trận đặc trưng có rank $< n$, nghĩa là có đặc trưng dư thừa (đa cộng tuyến) — mô hình hồi quy sẽ không có nghiệm duy nhất.
- **Trong NumPy:** `numpy.linalg.matrix_rank(A)` cho r; nullity $= A.shape[1] - r$. Cơ sở của null space lấy bằng `scipy.linalg.null_space(A)`.

Cho A là ma trận $m \times n$. Hệ quả 5.4.2 nói $\text{rank}\, A \leq m$ và $\text{rank}\, A \leq n$; tự nhiên ta hỏi khi nào xảy ra các trường hợp cực trị này. Hai định lý sau trả lời.

Định lý 5.4.3

Các mệnh đề sau là tương đương với ma trận A cỡ $m \times n$:

1. $\text{rank}\, A = n$.
2. Các hàng của A sinh ra $\mathbb{R}^n$.

3. Các cột của A độc lập tuyến tính trong $\mathbb{R}^m$.
4. Ma trận $n \times n$ là A^TA khả nghịch.
5. $CA = I_n$ với ma trận C cỡ $n \times m$ nào đó.
6. Nếu $A\mathbf{x} = \mathbf{0}$, $\mathbf{x}$ trong $\mathbb{R}^n$, thì $\mathbf{x} = \mathbf{0}$.

Chứng minh.

$(1) \Rightarrow (2)$. Ta có $\operatorname{row} A \subseteq \mathbb{R}^n$ và $\dim(\operatorname{row} A) = n$ theo (1), nên $\operatorname{row} A = \mathbb{R}^n$ theo Định lý 5.2.8.

$(2) \Rightarrow (3)$. Theo (2), $\operatorname{row} A = \mathbb{R}^n$ nên $\operatorname{rank} A = n$, tức $\dim(\operatorname{col} A) = n$. Vì n cột của A sinh ra $\operatorname{col} A$, chúng độc lập theo Định lý 5.2.7.

$(3) \Rightarrow (4)$. Nếu $(A^TA)\mathbf{x} = \mathbf{0}$, ta chứng minh $\mathbf{x} = \mathbf{0}$. Ta có

$$\|A\mathbf{x}\|^2 = (A\mathbf{x})^T A\mathbf{x} = \mathbf{x}^T A^T A\mathbf{x} = \mathbf{x}^T\mathbf{0} = 0$$

Do đó $A\mathbf{x} = \mathbf{0}$, nên $\mathbf{x} = \mathbf{0}$ theo (3) và Định lý 5.2.2.

$(4) \Rightarrow (5)$. Lấy $C = (A^TA)^{-1}A^T$.

$(5) \Rightarrow (6)$. Nếu $A\mathbf{x} = \mathbf{0}$, nhân trái bởi C cho $\mathbf{x} = \mathbf{0}$.

$(6) \Rightarrow (1)$. Theo (6), các cột của A độc lập theo Định lý 5.2.2. Do đó $\dim(\operatorname{col} A) = n$. ■

Định lý 5.4.4

Các mệnh đề sau là tương đương với ma trận A cỡ $m \times n$:

1. $\operatorname{rank} A = m$.
2. Các cột của A sinh ra $\mathbb{R}^m$.
3. Các hàng của A độc lập tuyến tính trong $\mathbb{R}^n$.
4. Ma trận $m \times m$ là AA^T khả nghịch.
5. $AC = I_m$ với ma trận C cỡ $n \times m$ nào đó.
6. Hệ $A\mathbf{x} = \mathbf{b}$ tương thích (có nghiệm) với mọi $\mathbf{b}$ trong $\mathbb{R}^m$.

Chứng minh.

$(1) \Rightarrow (2)$. Theo (1), $\dim(\operatorname{col} A) = m$, nên $\operatorname{col} A = \mathbb{R}^m$ theo Định lý 5.2.8.

$(2) \Rightarrow (3)$. Theo (2), $\operatorname{col} A = \mathbb{R}^m$ nên $\operatorname{rank} A = m$, tức $\dim(\operatorname{row} A) = m$. Vì m hàng của A sinh ra $\operatorname{row} A$, chúng độc lập theo Định lý 5.2.7.

$(3) \Rightarrow (4)$. Ta có $\operatorname{rank} A = m$ theo (3), nên ma trận A^T cỡ $n \times m$ có hạng m. Áp dụng Định lý 5.4.3 cho A^T thay cho A cho thấy $(A^T)^TA^T = AA^T$ khả nghịch.

$(4) \Rightarrow (5)$. Lấy $C = A^T(AA^T)^{-1}$.

$(5) \Rightarrow (6)$. So sánh các cột trong $AC = I_m$ cho $A\mathbf{c}_j = \mathbf{e}_j$ với mọi j. Cho $\mathbf{b}$ trong $\mathbb{R}^m$, viết $\mathbf{b} = \sum_{j=1}^m r_j\mathbf{e}_j$. Khi đó $A\mathbf{x} = \mathbf{b}$ đúng với $\mathbf{x} = \sum_{j=1}^m r_j\mathbf{c}_j$.

$(6) \Rightarrow (1)$. Theo (6), các cột của A sinh ra $\mathbb{R}^m$ theo Định lý 5.2.2. Vậy $\operatorname{col} A = \mathbb{R}^m$. ■

Ví dụ 5.4.4

Chứng minh $\begin{bmatrix} 3 & x+y+z \\ x+y+z & x^2+y^2+z^2 \end{bmatrix}$ khả nghịch nếu x, y, z không đồng thời bằng nhau.

Lời giải. Ma trận đã cho có dạng A^TA với $A = \begin{bmatrix} 1 & x \\ 1 & y \\ 1 & z \end{bmatrix}$, có các cột độc lập vì x, y, z không đồng thời bằng nhau (bạn hãy kiểm tra). Vậy Định lý 5.4.3 áp dụng được.

Định lý 5.4.3 và 5.4.4 liên hệ nhiều tính chất quan trọng của ma trận A cỡ $m \times n$ với tính khả nghịch của các ma trận vuông đối xứng A^TA và AA^T. Thực tế, ngay cả khi các cột của A không độc lập hoặc không sinh ra $\mathbb{R}^m$, cả A^TA và AA^T đều đối xứng và do đó có *trị riêng thực* — ta sẽ thấy ở Chương 7.

Ghi chú cho người học — A^TA và nghịch đảo giả (pseudo-inverse)

Ma trận $C = (A^TA)^{-1}A^T$ trong chứng minh $(4) \Rightarrow (5)$ có tên riêng: **nghịch đảo giả Moore–Penrose** (pseudo-inverse) của A, thường ký hiệu A^+. Đây là công cụ trung tâm của:

- **Hồi quy tuyến tính** (linear regression): nghiệm bình phương tối thiểu chính là $\hat{\beta} = (A^TA)^{-1}A^T\mathbf{y}$ — bạn sẽ gặp lại nó ở Mục 5.6.
- **Hệ phương trình không có nghiệm chính xác**: khi $A\mathbf{x} = \mathbf{b}$ vô nghiệm (nhiều phương trình hơn ẩn), $A^+\mathbf{b}$ cho *nghiệm gần đúng tốt nhất*.
- Trong NumPy: `numpy.linalg.pinv(A)`. Chú ý: **đừng** tự viết `inv(A.T @ A) @ A.T` — cách đó khuếch đại sai số số học rất mạnh. `pinv` dùng SVD, ổn định hơn nhiều; `numpy.linalg.lstsq(A, b)` còn tốt hơn nữa nếu bạn chỉ cần nghiệm.

5.5 Tính đồng dạng và chéo hóa

Ở Mục 3.3 ta đã học chéo hóa (diagonalization) ma trận vuông A và tìm được nhiều ứng dụng quan trọng (ví dụ cho hệ động lực tuyến tính). Giờ ta có thể dùng các khái niệm không gian con, cơ sở, số chiều để làm rõ quá trình chéo hóa, phát hiện kết quả mới, và chứng minh những định lý chưa chứng minh được ở Mục 3.3.

Ma trận đồng dạng

Định nghĩa 5.12 — Ma trận đồng dạng

Nếu A và B là các ma trận $n \times n$, ta nói A và B **đồng dạng** (similar), viết $A \sim B$, nếu

$$B = P^{-1}AP$$

với một ma trận khả nghịch P nào đó.

Chú ý $A \sim B$ khi và chỉ khi $B = QAQ^{-1}$ với Q khả nghịch (đặt $P^{-1} = Q$). Ngôn ngữ đồng dạng được dùng khắp đại số tuyến tính. Chẳng hạn, ma trận A chéo hóa được khi và chỉ khi nó đồng dạng với một ma trận chéo.

Nếu $A \sim B$ thì tất yếu $B \sim A$. Thật vậy, giả sử $B = P^{-1}AP$. Khi đó $A = PBP^{-1} = Q^{-1}BQ$ với

$Q = P^{-1}$ khả nghịch. Đó là tính chất thứ hai trong các tính chất sau:

$$\begin{aligned} &1.\ A \sim A \text{ với mọi ma trận vuông } A.\\ &2.\ \text{Nếu } A \sim B \text{ thì } B \sim A.\\ &3.\ \text{Nếu } A \sim B \text{ và } B \sim C \text{ thì } A \sim C. \end{aligned} \tag{5.2}$$

Các tính chất này thường được phát biểu gọn: quan hệ đồng dạng $\sim$ là một **quan hệ tương đương** (equivalence relation) trên tập các ma trận $n \times n$.

Ví dụ 5.5.1

Nếu A đồng dạng với B và một trong hai chéo hóa được, chứng minh ma trận kia cũng chéo hóa được.

Lời giải. Ta có $A \sim B$. Giả sử A chéo hóa được, tức $A \sim D$ với D chéo. Vì $B \sim A$ theo (2) của (5.2), ta có $B \sim A$ và $A \sim D$. Do đó $B \sim D$ theo (3) của (5.2), nên B cũng chéo hóa được. Lập luận tương tự nếu giả thiết B chéo hóa được.

Tính đồng dạng tương thích với nghịch đảo, chuyển vị và lũy thừa:

$$\text{Nếu } A \sim B \text{ thì } A^{-1} \sim B^{-1}, \quad A^T \sim B^T, \quad A^k \sim B^k \text{ với mọi số nguyên } k \geq 1$$

Chứng minh là tính toán ma trận thường quy dùng Định lý 3.3.1.

Định nghĩa 5.13 — Vết của ma trận

Vết (trace) $\operatorname{tr} A$ của ma trận $n \times n$ A được định nghĩa là tổng các phần tử trên đường chéo chính:

$$\text{Nếu } A = [a_{ij}] \text{ thì } \operatorname{tr} A = a_{11} + a_{22} + \cdots + a_{nn}$$

Hiển nhiên $\operatorname{tr}(A + B) = \operatorname{tr} A + \operatorname{tr} B$ và $\operatorname{tr}(cA) = c \operatorname{tr} A$. Sự kiện sau bất ngờ hơn.

Bổ đề 5.5.1

Cho A và B là ma trận $n \times n$. Khi đó $\operatorname{tr}(AB) = \operatorname{tr}(BA)$.

Chứng minh. Viết $A = [a_{ij}]$ và $B = [b_{ij}]$. Với mỗi i, phần tử (i, i) của AB là $d_i = \sum_j a_{ij} b_{ji}$. Do đó

$$\operatorname{tr}(AB) = \sum_i d_i = \sum_i \left(\sum_j a_{ij} b_{ji} \right)$$

Tương tự $\operatorname{tr}(BA) = \sum_i \left(\sum_j b_{ij} a_{ji} \right)$. Hai tổng kép này như nhau. ■

Định lý 5.5.1

Nếu A và B là hai ma trận $n \times n$ đồng dạng, thì A và B có cùng **định thức**, **hạng**, **vết**, **đa thức đặc trưng** và **trị riêng**.

Chứng minh. Cho $B = P^{-1}AP$. Khi đó

$$\det B = \det(P^{-1}) \det A \det P = \det A \quad \text{vì } \det(P^{-1}) = 1/\det P$$

Tương tự $\operatorname{rank} B = \operatorname{rank}(P^{-1}AP) = \operatorname{rank} A$ theo Hệ quả 5.4.3. Tiếp theo Bổ đề 5.5.1 cho

$$\operatorname{tr}(P^{-1}AP) = \operatorname{tr}\left(P^{-1}(AP)\right) = \operatorname{tr}\left((AP)P^{-1}\right) = \operatorname{tr} A$$

Với đa thức đặc trưng:

$$\begin{aligned} c_B(x) &= \det(xI - B) = \det\{x(P^{-1}IP) - P^{-1}AP\} \\ &= \det\{P^{-1}(xI - A)P\} = \det(xI - A) = c_A(x) \end{aligned}$$

Cuối cùng, điều này cho thấy A và B có cùng trị riêng vì trị riêng là nghiệm của đa thức đặc trưng. ■

Ví dụ 5.5.2

Có chung năm tính chất trong Định lý 5.5.1 **không** bảo đảm hai ma trận đồng dạng. Hai ma trận

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \qquad I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

có cùng định thức, hạng, vết, đa thức đặc trưng và trị riêng, nhưng *không* đồng dạng, vì $P^{-1}IP = I$ với mọi ma trận khả nghịch P.

Ghi chú cho người học — ”đồng dạng” nghĩa là gì về mặt trực giác

$B = P^{-1}AP$ nghĩa là: *A và B mô tả cùng một phép biến đổi, chỉ khác hệ tọa độ.*
Hình dung: P là ”phiên dịch viên” chuyển từ hệ tọa độ mới sang hệ cũ. Đọc $P^{-1}AP\mathbf{x}$ từ phải sang trái: dịch $\mathbf{x}$ sang hệ cũ (P), làm phép biến đổi ở đó (A), rồi dịch kết quả về hệ mới (P^{-1}).
Điều đó giải thích Định lý 5.5.1: định thức, hạng, vết, trị riêng là các *tính chất nội tại* của phép biến đổi, không phụ thuộc hệ tọa độ ta chọn để mô tả nó. Ngược lại, các phần tử cụ thể a_{ij} *có* phụ thuộc hệ tọa độ, nên chúng không được bảo toàn.
Ví dụ 5.5.2 là cảnh báo quan trọng: năm bất biến đó là *điều kiện cần*, không phải *điều kiện đủ*. Hai ma trận có thể trùng hết năm bất biến mà vẫn khác nhau về bản chất.

Trở lại chéo hóa

Nhắc lại: ma trận vuông A **chéo hóa được** nếu tồn tại ma trận khả nghịch P sao cho $P^{-1}AP = D$ là ma trận chéo. Tiếc là không phải mọi ma trận đều chéo hóa được, ví dụ $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$.

Nhắc lại: số λ gọi là **trị riêng** (eigenvalue) của A nếu $A\mathbf{x} = \lambda\mathbf{x}$ với cột $\mathbf{x} \neq \mathbf{0}$ nào đó, và mọi vector khác không như vậy gọi là **vector riêng** (eigenvector) ứng với λ. **Đa thức đặc trưng** là

$$c_A(x) = \det(xI - A)$$

Định lý 5.5.2

Cho A là ma trận $n \times n$.

1. Các trị riêng λ của A là các *nghiệm* của đa thức đặc trưng $c_A(x)$.
2. Các vector riêng $\mathbf{x}$ ứng với λ là các nghiệm *khác không* của hệ thuần nhất $(\lambda I - A)\mathbf{x} = \mathbf{0}$.

Ví dụ 5.5.3

Chứng minh trị riêng của ma trận tam giác chính là các phần tử trên đường chéo chính.
Lời giải. Giả sử A tam giác. Khi đó $xI - A$ cũng tam giác với các phần tử chéo $(x -$

$a_{11}), \ldots, (x - a_{nn})$. Do đó Định lý 3.1.4 cho

$$c_A(x) = (x - a_{11})(x - a_{22}) \cdots (x - a_{nn})$$

và kết quả suy ra vì trị riêng là nghiệm của $c_A(x)$.

Định lý 5.5.3

Cho A là ma trận $n \times n$.

1. A chéo hóa được khi và chỉ khi $\mathbb{R}^n$ có một **cơ sở** $\{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$ gồm toàn *vector riêng* của A.
2. Khi đó, ma trận $P = [\mathbf{x}_1\ \mathbf{x}_2\ \cdots\ \mathbf{x}_n]$ khả nghịch và
$$P^{-1}AP = \text{diag}(\lambda_1, \lambda_2, \ldots, \lambda_n)$$
trong đó λ_i là trị riêng ứng với $\mathbf{x}_i$.

Kết quả sau là công cụ cơ bản để xác định khi nào một ma trận chéo hóa được. Nó cho thấy một liên hệ quan trọng giữa trị riêng và tính độc lập tuyến tính.

Định lý 5.5.4

Cho $\mathbf{x}_1, \ldots, \mathbf{x}_k$ là các vector riêng ứng với các trị riêng **phân biệt** $\lambda_1, \ldots, \lambda_k$ của ma trận $n \times n$ A. Khi đó $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ là tập độc lập tuyến tính.

Chứng minh. Quy nạp theo k. Nếu $k = 1$ thì $\{\mathbf{x}_1\}$ độc lập vì $\mathbf{x}_1 \neq \mathbf{0}$. Tổng quát, giả sử định lý đúng với $k \geq 1$ nào đó. Cho các vector riêng $\{\mathbf{x}_1, \ldots, \mathbf{x}_{k+1}\}$, giả sử một tổ hợp tuyến tính triệt tiêu:

$$t_1\mathbf{x}_1 + t_2\mathbf{x}_2 + \cdots + t_{k+1}\mathbf{x}_{k+1} = \mathbf{0} \tag{5.3}$$

Ta phải chứng minh mọi $t_i = 0$. Nhân trái (5.3) bởi A và dùng $A\mathbf{x}_i = \lambda_i\mathbf{x}_i$:

$$t_1\lambda_1\mathbf{x}_1 + t_2\lambda_2\mathbf{x}_2 + \cdots + t_{k+1}\lambda_{k+1}\mathbf{x}_{k+1} = \mathbf{0} \tag{5.4}$$

Nhân (5.3) với λ_1 rồi trừ khỏi (5.4), số hạng đầu triệt tiêu và ta được

$$t_2(\lambda_2 - \lambda_1)\mathbf{x}_2 + t_3(\lambda_3 - \lambda_1)\mathbf{x}_3 + \cdots + t_{k+1}(\lambda_{k+1} - \lambda_1)\mathbf{x}_{k+1} = \mathbf{0}$$

Vì $\mathbf{x}_2, \ldots, \mathbf{x}_{k+1}$ ứng với các trị riêng phân biệt, tập $\{\mathbf{x}_2, \ldots, \mathbf{x}_{k+1}\}$ độc lập theo giả thiết quy nạp. Do đó

$$t_2(\lambda_2 - \lambda_1) = 0, \quad t_3(\lambda_3 - \lambda_1) = 0, \quad \ldots, \quad t_{k+1}(\lambda_{k+1} - \lambda_1) = 0$$

nên $t_2 = t_3 = \cdots = t_{k+1} = 0$ vì các λ_i phân biệt. Khi đó (5.3) trở thành $t_1\mathbf{x}_1 = \mathbf{0}$, kéo theo $t_1 = 0$ vì $\mathbf{x}_1 \neq \mathbf{0}$. ■

Định lý 5.5.5

Nếu A là ma trận $n \times n$ có n trị riêng **phân biệt**, thì A chéo hóa được.

Chứng minh. Chọn một vector riêng cho mỗi trị riêng trong n trị riêng phân biệt. Các vector riêng này độc lập theo Định lý 5.5.4, nên là cơ sở của $\mathbb{R}^n$ theo Định lý 5.2.7. Áp dụng Định lý 5.5.3. ■

Ví dụ 5.5.4

Chứng minh $A = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 2 & 3 \\ -1 & 1 & 0 \end{bmatrix}$ chéo hóa được.

Lời giải. Tính toán thường quy cho $c_A(x) = (x-1)(x-3)(x+1)$, nên A có các trị riêng phân biệt 1, 3, -1. Vậy Định lý 5.5.5 áp dụng được.

Tuy nhiên, một ma trận có thể có *trị riêng bội*. Để xử lý tình huống này, ta chứng minh một bổ đề quan trọng.

Bổ đề 5.5.2

Cho $\{\mathbf{x}_1, \ldots, \mathbf{x}_k\}$ là tập độc lập tuyến tính gồm các vector riêng của ma trận $n \times n$ A, mở rộng nó thành cơ sở $\{\mathbf{x}_1, \ldots, \mathbf{x}_k, \ldots, \mathbf{x}_n\}$ của $\mathbb{R}^n$, và đặt $P = [\,\mathbf{x}_1 \ \cdots \ \mathbf{x}_n\,]$. Nếu $\lambda_1, \ldots, \lambda_k$ là các trị riêng (không nhất thiết phân biệt) ứng với $\mathbf{x}_1, \ldots, \mathbf{x}_k$, thì $P^{-1}AP$ có dạng khối

$$P^{-1}AP = \begin{bmatrix} \operatorname{diag}(\lambda_1, \ldots, \lambda_k) & B \\ 0 & A_1 \end{bmatrix}$$

trong đó B cỡ $k \times (n-k)$ và A_1 cỡ $(n-k) \times (n-k)$.

Chứng minh. Nếu $\{\mathbf{e}_1, \ldots, \mathbf{e}_n\}$ là cơ sở chuẩn tắc, thì

$$[\,\mathbf{e}_1 \ \cdots \ \mathbf{e}_n\,] = I_n = P^{-1}P = P^{-1}[\,\mathbf{x}_1 \ \cdots \ \mathbf{x}_n\,] = [\,P^{-1}\mathbf{x}_1 \ \cdots \ P^{-1}\mathbf{x}_n\,]$$

So sánh cột: $P^{-1}\mathbf{x}_i = \mathbf{e}_i$ với mọi i. Mặt khác

$$P^{-1}AP = P^{-1}A[\,\mathbf{x}_1 \ \cdots \ \mathbf{x}_n\,] = [\,(P^{-1}A)\mathbf{x}_1 \ \cdots \ (P^{-1}A)\mathbf{x}_n\,]$$

Do đó nếu $1 \le i \le k$, cột i của $P^{-1}AP$ là

$$(P^{-1}A)\mathbf{x}_i = P^{-1}(\lambda_i \mathbf{x}_i) = \lambda_i (P^{-1}\mathbf{x}_i) = \lambda_i \mathbf{e}_i \qquad \blacksquare$$

Định nghĩa 5.14 — Không gian riêng của ma trận

Nếu λ là trị riêng của ma trận $n \times n$ A, định nghĩa **không gian riêng** (eigenspace) của A ứng với λ bởi

$$E_\lambda(A) = \{\mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} = \lambda\mathbf{x}\}$$

Đây là không gian con của $\mathbb{R}^n$, và các vector riêng ứng với λ chính là các vector khác không trong $E_\lambda(A)$. Thực ra $E_\lambda(A)$ là không gian nghiệm của ma trận $(\lambda I - A)$:

$$E_\lambda(A) = \{\mathbf{x} \mid (\lambda I - A)\mathbf{x} = \mathbf{0}\} = \operatorname{null}(\lambda I - A)$$

Do đó, theo Định lý 5.4.2, các nghiệm cơ bản của hệ thuần nhất $(\lambda I - A)\mathbf{x} = \mathbf{0}$ do thuật toán Gauss cho lập thành một cơ sở của $E_\lambda(A)$. Đặc biệt

$$\dim E_\lambda(A) \text{ là số nghiệm cơ bản của } (\lambda I - A)\mathbf{x} = \mathbf{0} \tag{5.5}$$

Nhắc lại (Định nghĩa 3.7): **bội** (multiplicity) của trị riêng λ của A là số lần λ xuất hiện như nghiệm của $c_A(x)$; tức là số nguyên $m \ge 1$ lớn nhất sao cho $c_A(x) = (x-\lambda)^m g(x)$ với đa thức $g(x)$ nào đó.[3]

[3] Đại lượng này thường được gọi là *bội đại số* (algebraic multiplicity) của λ; còn $\dim E_\lambda(A)$ gọi là *bội hình học* (geometric multiplicity).

Bổ đề 5.5.3

Cho λ là trị riêng bội m của ma trận vuông A. Khi đó $\dim[E_\lambda(A)] \leq m$.

Chứng minh. Đặt $\dim[E_\lambda(A)] = d$. Chỉ cần chứng minh $c_A(x) = (x-\lambda)^d g(x)$ với đa thức $g(x)$ nào đó, vì m là lũy thừa cao nhất của $(x-\lambda)$ chia hết $c_A(x)$. Cho $\{\mathbf{x}_1, \ldots, \mathbf{x}_d\}$ là cơ sở của $E_\lambda(A)$. Bổ đề 5.5.2 cho thấy tồn tại ma trận khả nghịch P sao cho

$$P^{-1}AP = \begin{bmatrix} \lambda I_d & B \\ 0 & A_1 \end{bmatrix}$$

Đặt $A' = P^{-1}AP$; ta có $c_{A'}(x) = c_A(x)$ theo Định lý 5.5.1. Định lý 3.1.5 cho

$$\begin{aligned} c_A(x) = c_{A'}(x) = \det(xI_n - A') &= \det \begin{bmatrix} (x-\lambda)I_d & -B \\ 0 & xI_{n-d} - A_1 \end{bmatrix} \\ &= \det[(x-\lambda)I_d] \cdot \det[xI_{n-d} - A_1] = (x-\lambda)^d g(x) \end{aligned}$$

với $g(x) = c_{A_1}(x)$. ■

Định lý 5.5.6

Các mệnh đề sau là tương đương với ma trận vuông A có $c_A(x)$ *phân tích được hoàn toàn* (thành tích các nhân tử tuyến tính trên $\mathbb{R}$):

1. A chéo hóa được.
2. $\dim[E_\lambda(A)]$ bằng *bội* của λ, với *mọi* trị riêng λ của A.

Chứng minh. Cho A cỡ $n \times n$ và $\lambda_1, \ldots, \lambda_k$ là các trị riêng phân biệt. Với mỗi i, gọi m_i là bội của λ_i và $d_i = \dim E_{\lambda_i}(A)$. Khi đó

$$c_A(x) = (x-\lambda_1)^{m_1}(x-\lambda_2)^{m_2}\cdots(x-\lambda_k)^{m_k}$$

nên $m_1 + \cdots + m_k = n$ vì $c_A(x)$ có bậc n. Hơn nữa $d_i \leq m_i$ với mọi i theo Bổ đề 5.5.3.

(1) $\Rightarrow$ (2). Theo (1), $\mathbb{R}^n$ có cơ sở gồm n vector riêng của A; gọi t_i là số vector nằm trong $E_{\lambda_i}(A)$. Vì không gian con sinh bởi t_i vector riêng đó có số chiều t_i, ta có $t_i \leq d_i$ theo Định lý 5.2.4. Do đó

$$n = t_1 + \cdots + t_k \leq d_1 + \cdots + d_k \leq m_1 + \cdots + m_k = n$$

Suy ra $d_1 + \cdots + d_k = m_1 + \cdots + m_k$, và vì $d_i \leq m_i$ với mọi i, ta buộc phải có $d_i = m_i$.

(2) $\Rightarrow$ (1). Gọi B_i là cơ sở của $E_{\lambda_i}(A)$, và $B = B_1 \cup \cdots \cup B_k$. Vì mỗi B_i chứa m_i vector theo (2), và các B_i rời nhau từng đôi (các λ_i phân biệt), B chứa n vector. Nên chỉ cần chứng minh B độc lập tuyến tính. Giả sử một tổ hợp tuyến tính các vector trong B triệt tiêu, gọi $\mathbf{y}_i$ là tổng các số hạng đến từ B_i. Khi đó $\mathbf{y}_i$ nằm trong $E_{\lambda_i}(A)$, nên các $\mathbf{y}_i$ khác không là độc lập theo Định lý 5.5.4. Vì tổng các $\mathbf{y}_i$ bằng không, suy ra $\mathbf{y}_i = \mathbf{0}$ với mọi i. Do đó mọi hệ số trong $\mathbf{y}_i$ bằng 0 (vì B_i độc lập). Điều này đúng với mọi i, nên B độc lập. ■

Ví dụ 5.5.5

Nếu $A = \begin{bmatrix} 5 & 8 & 16 \\ 4 & 1 & 8 \\ -4 & -4 & -11 \end{bmatrix}$ và $B = \begin{bmatrix} 2 & 1 & 1 \\ 2 & 1 & -2 \\ -1 & 0 & -2 \end{bmatrix}$, chứng minh A chéo hóa được nhưng B thì không.

Lời giải. Ta có $c_A(x) = (x+3)^2(x-1)$ nên trị riêng là $\lambda_1 = -3$ và $\lambda_2 = 1$. Các không gian riêng tương ứng là $E_{\lambda_1}(A) = \text{span}\{\mathbf{x}_1, \mathbf{x}_2\}$ và $E_{\lambda_2}(A) = \text{span}\{\mathbf{x}_3\}$ với

$$\mathbf{x}_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} -2 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix}$$

Vì $\{\mathbf{x}_1, \mathbf{x}_2\}$ độc lập, $\dim(E_{\lambda_1}(A)) = 2$ — đúng bằng bội của λ_1. Tương tự $\dim(E_{\lambda_2}(A)) = 1$ bằng bội của λ_2. Vậy A chéo hóa được theo Định lý 5.5.6, với ma trận chéo hóa $P = [\mathbf{x}_1\ \mathbf{x}_2\ \mathbf{x}_3]$.
Với B: $c_B(x) = (x+1)^2(x-3)$ nên trị riêng là $\lambda_1 = -1$ và $\lambda_2 = 3$. Các không gian riêng là $E_{\lambda_1}(B) = \text{span}\{\mathbf{y}_1\}$ và $E_{\lambda_2}(B) = \text{span}\{\mathbf{y}_2\}$ với

$$\mathbf{y}_1 = \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix}, \quad \mathbf{y}_2 = \begin{bmatrix} 5 \\ 6 \\ -1 \end{bmatrix}$$

Ở đây $\dim(E_{\lambda_1}(B)) = 1$ *nhỏ hơn* bội 2 của λ_1, nên B **không** chéo hóa được theo Định lý 5.5.6. Việc $\dim(E_{\lambda_1}(B)) = 1$ nghĩa là không có cách nào tìm được ba vector riêng độc lập tuyến tính.

Ghi chú cho người học — quy trình chéo hóa, viết thành thuật toán

Gộp mục 5.5 lại thành một quy trình bạn có thể thực hiện từng bước:

1. Tính $c_A(x) = \det(xI - A)$.
2. Tìm nghiệm $\Rightarrow$ các trị riêng λ_i và *bội đại số* m_i của mỗi trị riêng.
3. Với mỗi λ_i: giải $(\lambda_i I - A)\mathbf{x} = \mathbf{0}$, đếm số nghiệm cơ bản $\Rightarrow d_i = \dim E_{\lambda_i}$ (*bội hình học*).
4. So sánh: nếu $d_i = m_i$ với **mọi** $i \Rightarrow$ chéo hóa được. Nếu có một i mà $d_i < m_i \Rightarrow$ **không**.
5. Nếu được: xếp toàn bộ vector cơ sở của các E_{λ_i} thành cột của P; khi đó $P^{-1}AP = D$ với D chứa các λ_i theo đúng thứ tự cột.

Đường tắt: nếu bước 2 cho n trị riêng phân biệt, dừng lại — chắc chắn chéo hóa được (Định lý 5.5.5), khỏi cần bước 3–4.
Vì sao dân IT cần cái này: $A^k = PD^kP^{-1}$, mà D^k chỉ là nâng lũy thừa từng phần tử chéo. Đây là cách tính lũy thừa ma trận trong $O(\log k)$ thay vì $O(k)$ — dùng cho Markov chain, PageRank, Fibonacci, và phân tích độ ổn định của hệ động lực. Trong NumPy: `numpy.linalg.eig(A)` trả về $(\text{trị riêng}, P)$.
Cảnh báo thực tế: ma trận không chéo hóa được là "hiếm" theo nghĩa toán học, nhưng ma trận *gần* không chéo hóa được thì rất hay gặp, và chúng gây mất ổn định số nghiêm trọng. Trong thực hành, người ta thường dùng **SVD** (`numpy.linalg.svd`) hoặc **phân rã Schur** thay vì chéo hóa, vì chúng luôn tồn tại và luôn ổn định.

Trị riêng phức

Mọi ma trận ta xét đến giờ đều có trị riêng thực. Nhưng điều đó không nhất thiết đúng: ma trận $A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ có $c_A(x) = x^2 + 1$, không có nghiệm thực. Dù vậy ma trận này *vẫn* chéo hóa được; khác biệt duy nhất là ta phải dùng một tập vô hướng rộng hơn — **số phức**.

Thực tế, gần như mọi thứ ta đã làm cho ma trận thực đều làm được cho ma trận phức. Phương pháp giống hệt; chỉ khác là số học thực hiện với số phức. Nhưng số phức *tốt hơn* số thực ở một điểm: mọi đa thức không hằng với hệ số phức đều có nghiệm phức, và do đó phân tích hoàn toàn thành tích các nhân tử tuyến tính. Đây là **định lý cơ bản của đại số** (fundamental theorem of algebra).[4]

Ví dụ 5.5.6

Chéo hóa ma trận $A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$.

Lời giải. Đa thức đặc trưng của A là

$$c_A(x) = \det(xI - A) = x^2 + 1 = (x - i)(x + i), \quad i^2 = -1$$

Vậy trị riêng là $\lambda_1 = i$ và $\lambda_2 = -i$, với các vector riêng tương ứng $\mathbf{x}_1 = \begin{bmatrix} 1 \\ -i \end{bmatrix}$ và $\mathbf{x}_2 = \begin{bmatrix} 1 \\ i \end{bmatrix}$.

Do đó A chéo hóa được theo phiên bản phức của Định lý 5.5.5, và phiên bản phức của Định lý 5.5.3 cho thấy $P = [\,\mathbf{x}_1\ \mathbf{x}_2\,] = \begin{bmatrix} 1 & 1 \\ -i & i \end{bmatrix}$ khả nghịch và

$$P^{-1}AP = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = \begin{bmatrix} i & 0 \\ 0 & -i \end{bmatrix}$$

Ghi chú — ma trận này là phép quay $90°$

$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ chính là ma trận quay $90°$ trong mặt phẳng. Việc nó không có trị riêng thực có ý nghĩa hình học rất rõ: *một phép quay $90°$ không giữ nguyên phương của bất kỳ vector nào*. Mọi vector đều bị xoay đi, không vector nào chỉ bị co giãn.
Trị riêng phức $\pm i$ mã hóa chính góc quay: nói chung, trị riêng phức $re^{i\theta}$ của ma trận thực 2×2 tương ứng với phép "quay góc θ kèm co giãn hệ số r". Đây là lý do trị riêng phức xuất hiện khắp nơi khi phân tích dao động, tín hiệu tuần hoàn và hệ điều khiển.

Ma trận đối xứng

Nhiều ứng dụng của đại số tuyến tính liên quan tới ma trận thực A; và dù A sẽ có trị riêng phức theo định lý cơ bản của đại số, ta luôn muốn biết khi nào các trị riêng *thực sự là thực*. Điều này xảy ra bất cứ khi nào A **đối xứng**.

Ký hiệu $\overline{z}$ là liên hợp của số phức z. Nếu A là ma trận phức, ma trận liên hợp $\overline{A}$ là ma trận thu được bằng cách liên hợp từng phần tử. Ta có $\overline{A + B} = \overline{A} + \overline{B}$, $\overline{AB} = \overline{A}\,\overline{B}$ và $\overline{\lambda A} = \overline{\lambda}\,\overline{A}$.

[4] Đây là bài toán mở nổi tiếng năm 1799, khi Gauss giải nó ở tuổi 22 trong luận án tiến sĩ của mình.

Định lý 5.5.7

Cho A là ma trận thực **đối xứng**. Nếu λ là trị riêng phức bất kỳ của A, thì λ là số **thực**.[a]

[a] Định lý này được Augustin Louis Cauchy chứng minh lần đầu năm 1829.

Chứng minh. Chú ý $\overline{A} = A$ vì A thực. Nếu λ là trị riêng, ta chứng minh λ thực bằng cách chứng minh $\lambda = \overline{\lambda}$. Cho $\mathbf{x}$ là vector riêng (có thể phức) ứng với λ, nên $\mathbf{x} \neq \mathbf{0}$ và $A\mathbf{x} = \lambda\mathbf{x}$. Đặt $c = \overline{\mathbf{x}}^T\mathbf{x}$.

Nếu viết $\mathbf{x} = \begin{bmatrix} z_1 & z_2 & \cdots & z_n \end{bmatrix}^T$ với z_i là số phức, ta có

$$c = \overline{\mathbf{x}}^T\mathbf{x} = \overline{z_1}z_1 + \overline{z_2}z_2 + \cdots + \overline{z_n}z_n = |z_1|^2 + |z_2|^2 + \cdots + |z_n|^2$$

Vậy c là số thực và $c > 0$ vì ít nhất một $z_i \neq 0$ (do $\mathbf{x} \neq \mathbf{0}$). Ta chứng minh $\lambda = \overline{\lambda}$ bằng cách kiểm tra $\lambda c = \overline{\lambda} c$. Ta có

$$\lambda c = \overline{\mathbf{x}}^T(\lambda\mathbf{x}) = \overline{\mathbf{x}}^T(A\mathbf{x}) = (A^T\overline{\mathbf{x}})^T\mathbf{x}$$

Tại đây ta dùng giả thiết *A đối xứng và thực*: $A^T = A = \overline{A}$, nên tiếp tục:

$$\lambda c = (\overline{A}\,\overline{\mathbf{x}})^T\mathbf{x} = \left(\overline{A\mathbf{x}}\right)^T\mathbf{x} = \left(\overline{\lambda\mathbf{x}}\right)^T\mathbf{x} = \overline{\lambda}\,\overline{\mathbf{x}}^T\mathbf{x} = \overline{\lambda} c$$

như yêu cầu. ■

Ví dụ 5.5.7

Kiểm chứng Định lý 5.5.7 cho mọi ma trận thực đối xứng 2×2.

Lời giải. Nếu $A = \begin{bmatrix} a & b \\ b & c \end{bmatrix}$ thì $c_A(x) = x^2 - (a+c)x + (ac - b^2)$, nên trị riêng là

$$\lambda = \tfrac{1}{2}\left[(a+c) \pm \sqrt{(a+c)^2 - 4(ac - b^2)}\right]$$

Nhưng ở đây

$$(a+c)^2 - 4(ac - b^2) = (a-c)^2 + 4b^2 \geq 0$$

với mọi a, b, c. Vậy các trị riêng là số thực.

Ghi chú cho người học — vì sao "đối xứng" lại quý đến thế

Định lý 5.5.7 là một trong những định lý được dùng nhiều nhất trong toàn bộ toán ứng dụng. Ma trận đối xứng thực:

- luôn có trị riêng *thực* (Định lý 5.5.7),
- luôn chéo hóa được, và hơn thế, chéo hóa được bằng một ma trận *trực giao* (sẽ học ở Chương 8 — Định lý phổ, Spectral Theorem).

Bạn gặp ma trận đối xứng ở đâu:

- **Ma trận hiệp phương sai** (covariance) trong thống kê và PCA — luôn đối xứng theo xây dựng.
- **Ma trận kề** của đồ thị *vô hướng* — đối xứng; trị riêng của nó cho biết cấu trúc cụm, tính liên thông (spectral graph theory, dùng trong phát hiện cộng đồng và phân tích mạng).
- **Ma trận Hessian** trong tối ưu hóa — dấu của trị riêng cho biết điểm dừng là cực tiểu, cực đại hay điểm yên ngựa.

- A^TA **và** AA^T (Mục 5.4) — luôn đối xứng, là nền tảng của SVD.

Bài học thực dụng: khi viết code, nếu bạn *biết* ma trận đối xứng, hãy dùng `numpy.linalg.eigh` thay vì `eig`. Hàm `eigh` khai thác tính đối xứng — nhanh hơn, chính xác hơn, và bảo đảm trả về trị riêng thực thay vì số phức có phần ảo nhiễu cỡ 10^{-16}.

5.6 Xấp xỉ tốt nhất và bình phương tối thiểu

Trong toán ứng dụng, nghiệm *chính xác* của một bài toán thường khó tìm. Tuy nhiên, tìm được xấp xỉ gần tùy ý thường cũng hữu ích không kém. Một trường hợp cơ bản là khi một hệ phương trình tuyến tính **vô nghiệm**, và ta muốn tìm một "xấp xỉ tốt nhất" cho nghiệm. Trong mục này ta định nghĩa xấp xỉ tốt nhất và mô tả phương pháp tìm nó, rồi áp dụng vào xấp xỉ dữ liệu bằng **bình phương tối thiểu** (least squares).

Giả sử A là ma trận $m \times n$ và $\mathbf{b}$ là cột trong $\mathbb{R}^m$, xét hệ

$$A\mathbf{x} = \mathbf{b}$$

gồm m phương trình tuyến tính với n ẩn. Hệ này không nhất thiết có nghiệm. Tuy nhiên, với cột $\mathbf{z} \in \mathbb{R}^n$ bất kỳ, khoảng cách $\|\mathbf{b} - A\mathbf{z}\|$ đo được $A\mathbf{z}$ cách $\mathbf{b}$ bao xa. Vậy tự nhiên ta hỏi: có tồn tại cột $\mathbf{z}$ trong $\mathbb{R}^n$ sao cho $\|\mathbf{b} - A\mathbf{z}\|$ là *giá trị nhỏ nhất* của $\|\mathbf{b} - A\mathbf{x}\|$ khi $\mathbf{x}$ chạy khắp $\mathbb{R}^n$ hay không?

Câu trả lời là **có**. Đặt

$$U = \{A\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n\}$$

Đây là không gian con của $\mathbb{R}^m$, và ta muốn một vector $A\mathbf{z}$ trong U gần $\mathbf{b}$ nhất có thể. Sự tồn tại của vector như vậy được bảo đảm bởi **định lý chiếu** (projection theorem), sẽ chứng minh ở Chương 8 (Định lý 8.1.3). Hơn nữa, định lý chiếu còn cho cách tính $\mathbf{z}$ đơn giản, vì nó chỉ ra rằng vector $\mathbf{b} - A\mathbf{z}$ **trực giao** với mọi vector $A\mathbf{x}$ trong U. Do đó với mọi $\mathbf{x}$ trong $\mathbb{R}^n$:

$$0 = (A\mathbf{x}) \cdot (\mathbf{b} - A\mathbf{z}) = (A\mathbf{x})^T(\mathbf{b} - A\mathbf{z}) = \mathbf{x}^T A^T(\mathbf{b} - A\mathbf{z}) = \mathbf{x} \cdot \left[A^T(\mathbf{b} - A\mathbf{z})\right]$$

Nói cách khác, vector $A^T(\mathbf{b} - A\mathbf{z})$ trong $\mathbb{R}^n$ trực giao với *mọi* vector trong $\mathbb{R}^n$, nên nó phải bằng $\mathbf{0}$ (vì nó trực giao với chính nó). Do đó $\mathbf{z}$ thỏa

$$(A^TA)\mathbf{z} = A^T\mathbf{b}$$

Định nghĩa 5.15 — Phương trình chuẩn tắc

Hệ phương trình $(A^TA)\mathbf{z} = A^T\mathbf{b}$ được gọi là **hệ phương trình chuẩn tắc** (normal equations) cho $\mathbf{z}$.

Chú ý hệ này *có thể* có nhiều hơn một nghiệm. Tuy nhiên ma trận $n \times n$ A^TA khả nghịch khi (và chỉ khi) các cột của A độc lập tuyến tính (Định lý 5.4.3); trong trường hợp đó $\mathbf{z}$ được xác định duy nhất bởi $\mathbf{z} = (A^TA)^{-1}A^T\mathbf{b}$. Tuy nhiên, cách hiệu quả nhất để tìm $\mathbf{z}$ là áp dụng *khử Gauss* cho hệ phương trình chuẩn tắc.

Định lý 5.6.1 — Định lý xấp xỉ tốt nhất

Cho A là ma trận $m \times n$, $\mathbf{b}$ là cột bất kỳ trong $\mathbb{R}^m$, xét hệ $A\mathbf{x} = \mathbf{b}$.

1. Mọi nghiệm $\mathbf{z}$ của hệ phương trình chuẩn tắc $(A^TA)\mathbf{z} = A^T\mathbf{b}$ đều là **xấp xỉ tốt nhất** cho nghiệm của $A\mathbf{x} = \mathbf{b}$, theo nghĩa $\|\mathbf{b} - A\mathbf{z}\|$ là giá trị nhỏ nhất của $\|\mathbf{b} - A\mathbf{x}\|$ khi $\mathbf{x}$

chạy khắp $\mathbb{R}^n$.

2. Nếu các cột của A độc lập tuyến tính, thì A^TA khả nghịch và $\mathbf{z}$ được xác định *duy nhất* bởi $\mathbf{z} = (A^TA)^{-1}A^T\mathbf{b}$.

Chú ý nếu A là $n \times n$ và khả nghịch, thì

$$\mathbf{z} = (A^TA)^{-1}A^T\mathbf{b} = A^{-1}\mathbf{b}$$

chính là nghiệm của hệ, và $\|\mathbf{b} - A\mathbf{z}\| = 0$. Vậy nếu A có các cột độc lập, $(A^TA)^{-1}A^T$ đóng vai trò "nghịch đảo" của ma trận *không vuông* A. Ma trận $A^T(AA^T)^{-1}$ đóng vai trò tương tự khi các *hàng* của A độc lập. Cả hai là trường hợp riêng của **nghịch đảo suy rộng** (generalized inverse) của ma trận A.

Ví dụ 5.6.1

Hệ phương trình tuyến tính

$$3x - y = 4, \qquad x + 2y = 0, \qquad 2x + y = 1$$

vô nghiệm. Tìm vector $\mathbf{z} = \begin{bmatrix} x_0 \\ y_0 \end{bmatrix}$ xấp xỉ tốt nhất một nghiệm.

Lời giải. Ở đây

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 2 \\ 2 & 1 \end{bmatrix}, \qquad A^TA = \begin{bmatrix} 3 & 1 & 2 \\ -1 & 2 & 1 \end{bmatrix} \begin{bmatrix} 3 & -1 \\ 1 & 2 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 14 & 1 \\ 1 & 6 \end{bmatrix}$$

là khả nghịch. Hệ phương trình chuẩn tắc $(A^TA)\mathbf{z} = A^T\mathbf{b}$ là

$$\begin{bmatrix} 14 & 1 \\ 1 & 6 \end{bmatrix} \mathbf{z} = \begin{bmatrix} 14 \\ -3 \end{bmatrix}, \qquad \text{nên} \qquad \mathbf{z} = \tfrac{1}{83} \begin{bmatrix} 87 \\ -56 \end{bmatrix}$$

Vậy $x_0 = \frac{87}{83}$ và $y_0 = \frac{-56}{83}$. Với các giá trị này, vế trái của các phương trình xấp xỉ bằng

$$3x_0 - y_0 = \tfrac{317}{83} \approx 3{,}82, \qquad x_0 + 2y_0 = \tfrac{-25}{83} \approx -0{,}30, \qquad 2x_0 + y_0 = \tfrac{118}{83} \approx 1{,}42$$

(so với vế phải thực tế là 4, 0, 1). Đây là mức gần nhất có thể đạt được.

Ví dụ 5.6.2

Số bàn thắng trung bình g mỗi trận của một cầu thủ khúc côn cầu dường như phụ thuộc tuyến tính vào hai yếu tố: số năm kinh nghiệm x_1 và số bàn thắng x_2 trong 10 trận trước đó. Dữ liệu được thu thập từ bốn cầu thủ. Tìm hàm tuyến tính $g = a_0 + a_1x_1 + a_2x_2$ khớp dữ liệu tốt nhất.

g	x_1	x_2
0,8	5	3
0,8	3	4
0,6	1	5
0,4	2	1

Lời giải. Nếu quan hệ là $g = r_0 + r_1x_1 + r_2x_2$, dữ liệu mô tả được bởi

$$\begin{bmatrix} 1 & 5 & 3 \\ 1 & 3 & 4 \\ 1 & 1 & 5 \\ 1 & 2 & 1 \end{bmatrix} \begin{bmatrix} r_0 \\ r_1 \\ r_2 \end{bmatrix} = \begin{bmatrix} 0{,}8 \\ 0{,}8 \\ 0{,}6 \\ 0{,}4 \end{bmatrix}$$

Dùng ký hiệu của Định lý 5.6.1:

$$\mathbf{z} = (A^TA)^{-1}A^T\mathbf{b} = \tfrac{1}{42}\begin{bmatrix} 119 & -17 & -19 \\ -17 & 5 & 1 \\ -19 & 1 & 5 \end{bmatrix}\begin{bmatrix} 1 & 1 & 1 & 1 \\ 5 & 3 & 1 & 2 \\ 3 & 4 & 5 & 1 \end{bmatrix}\begin{bmatrix} 0{,}8 \\ 0{,}8 \\ 0{,}6 \\ 0{,}4 \end{bmatrix} = \begin{bmatrix} 0{,}14 \\ 0{,}09 \\ 0{,}08 \end{bmatrix}$$

Vậy hàm khớp tốt nhất là $g = 0{,}14 + 0{,}09x_1 + 0{,}08x_2$. Khối lượng tính toán sẽ giảm đáng kể nếu ta lập hệ phương trình chuẩn tắc rồi giải bằng khử Gauss, thay vì tính ma trận nghịch đảo.

Xấp xỉ bình phương tối thiểu

Trong nhiều nghiên cứu khoa học, dữ liệu thu thập liên hệ hai biến. Chẳng hạn x là số tiền chi cho quảng cáo và y là giá trị doanh số vùng đó. Giả sử ta biết tồn tại quan hệ tuyến tính $y = a + bx$. Khi vẽ dữ liệu, các điểm $(x_1, y_1), \ldots, (x_n, y_n)$ có thể trông như nằm trên một đường thẳng, và việc ước lượng a, b đòi hỏi tìm đường thẳng *khớp tốt nhất* qua các điểm đó.

Lưu ý một khớp *chính xác* chỉ đạt được nếu $y_i = a + bx_i$ đúng với *mọi* điểm dữ liệu — nhưng kỳ vọng đó là quá đáng. Sai số đo đạc thực nghiệm chắc chắn xảy ra, nên a và b phải được chọn sao cho sai lệch giữa giá trị quan sát y_i và giá trị khớp $a + bx_i$ được *tối thiểu hóa* theo một nghĩa nào đó. Bình phương tối thiểu là một cách làm việc đó.

Viết hàm tuyến tính là $f(x) = r_0 + r_1x$, nên các điểm khớp (trên đường thẳng) có tọa độ $(x_1, f(x_1)), \ldots, (x_n, f(x_n))$. Với mỗi i, điểm quan sát (x_i, y_i) và điểm khớp $(x_i, f(x_i))$ không nhất thiết trùng nhau, và khoảng cách d_i giữa chúng đo mức "trượt" của đường thẳng so với điểm quan sát. Vì lý do đó d_i thường được gọi là **sai số** tại x_i.

Một cách đo tự nhiên độ gần của đường thẳng $y = f(x)$ với dữ liệu là tổng $d_1 + d_2 + \cdots + d_n$. Tuy nhiên, hóa ra dùng *tổng các bình phương*

$$S = d_1^2 + d_2^2 + \cdots + d_n^2$$

làm thước đo sai số thì tốt hơn, và đường thẳng $y = f(x)$ được chọn sao cho tổng này *nhỏ nhất*. Đường thẳng đó gọi là **đường thẳng xấp xỉ bình phương tối thiểu** (least squares approximating line).

Bình phương sai số d_i là $d_i^2 = [y_i - f(x_i)]^2$, nên đại lượng cần cực tiểu hóa là

$$S = [y_1 - f(x_1)]^2 + [y_2 - f(x_2)]^2 + \cdots + [y_n - f(x_n)]^2$$

Đặt

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad f(\mathbf{x}) = \begin{bmatrix} f(x_1) \\ \vdots \\ f(x_n) \end{bmatrix} = \begin{bmatrix} r_0 + r_1x_1 \\ \vdots \\ r_0 + r_1x_n \end{bmatrix}$$

Khi đó bài toán thành: chọn r_0, r_1 sao cho $S = \|\mathbf{y} - f(\mathbf{x})\|^2$ nhỏ nhất. Viết

$$M = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \qquad \mathbf{r} = \begin{bmatrix} r_0 \\ r_1 \end{bmatrix}$$

Khi đó $M\mathbf{r} = f(\mathbf{x})$, nên ta tìm cột $\mathbf{r}$ sao cho $\|\mathbf{y} - M\mathbf{r}\|^2$ nhỏ nhất — tức là tìm *xấp xỉ tốt nhất* $\mathbf{z}$ cho hệ $M\mathbf{r} = \mathbf{y}$. Định lý 5.6.1 áp dụng trực tiếp:

Định lý 5.6.2

Cho n điểm dữ liệu $(x_1, y_1), \ldots, (x_n, y_n)$, trong đó ít nhất hai trong các x_i phân biệt. Đặt

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \qquad M = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

Khi đó đường thẳng xấp xỉ bình phương tối thiểu có phương trình

$$y = z_0 + z_1 x$$

trong đó $\mathbf{z} = \begin{bmatrix} z_0 \\ z_1 \end{bmatrix}$ tìm bằng khử Gauss từ hệ phương trình chuẩn tắc

$$(M^T M)\mathbf{z} = M^T \mathbf{y}$$

Điều kiện ít nhất hai x_i phân biệt bảo đảm $M^T M$ khả nghịch, nên $\mathbf{z}$ duy nhất: $\mathbf{z} = (M^T M)^{-1} M^T \mathbf{y}$.

Ví dụ 5.6.3

Cho các điểm dữ liệu trong bảng sau. Tìm đường thẳng xấp xỉ bình phương tối thiểu.

x	y
1	1
3	2
4	3
6	4
7	5

Lời giải. Ta có

$$M^T M = \begin{bmatrix} 5 & x_1 + \cdots + x_5 \\ x_1 + \cdots + x_5 & x_1^2 + \cdots + x_5^2 \end{bmatrix} = \begin{bmatrix} 5 & 21 \\ 21 & 111 \end{bmatrix}$$

$$M^T \mathbf{y} = \begin{bmatrix} y_1 + \cdots + y_5 \\ x_1 y_1 + \cdots + x_5 y_5 \end{bmatrix} = \begin{bmatrix} 15 \\ 78 \end{bmatrix}$$

nên hệ phương trình chuẩn tắc $(M^TM)\mathbf{z} = M^T\mathbf{y}$ là

$$\begin{bmatrix} 5 & 21 \\ 21 & 111 \end{bmatrix} \begin{bmatrix} z_0 \\ z_1 \end{bmatrix} = \begin{bmatrix} 15 \\ 78 \end{bmatrix}$$

Nghiệm (bằng khử Gauss) là $\mathbf{z} = \begin{bmatrix} 0{,}24 \\ 0{,}66 \end{bmatrix}$ (làm tròn hai chữ số thập phân), nên đường thẳng xấp xỉ bình phương tối thiểu là

$$y = 0{,}24 + 0{,}66x$$

Chú ý M^TM quả thực khả nghịch ở đây (định thức bằng 114), và nghiệm chính xác là

$$\mathbf{z} = (M^TM)^{-1}M^T\mathbf{y} = \tfrac{1}{114}\begin{bmatrix} 111 & -21 \\ -21 & 5 \end{bmatrix}\begin{bmatrix} 15 \\ 78 \end{bmatrix} = \tfrac{1}{114}\begin{bmatrix} 27 \\ 75 \end{bmatrix} = \tfrac{1}{38}\begin{bmatrix} 9 \\ 25 \end{bmatrix}$$

Ghi chú cho người học — đây chính là ”linear regression”

Định lý 5.6.2 *là* hồi quy tuyến tính (linear regression) — thứ bạn gặp ở buổi học machine learning đầu tiên. Ba điều đáng nhớ:
1. Vì sao lại bình phương sai số, không phải trị tuyệt đối? Ba lý do: (a) bình phương khả vi ở mọi nơi, còn $|d|$ thì không, nên bài toán giải được bằng đại số tuyến tính thuần túy; (b) nó dẫn thẳng tới hệ phương trình chuẩn tắc — có công thức đóng, không cần lặp; (c) về mặt thống kê, nó là ước lượng hợp lý cực đại nếu nhiễu có phân phối chuẩn. *Nhược điểm:* bình phương khuếch đại ảnh hưởng của điểm ngoại lai (outlier). Nếu dữ liệu có nhiễu nặng, người ta dùng hồi quy L_1 (least absolute deviations) hoặc Huber loss thay thế.
2. Trực giao là ý tưởng cốt lõi. Nghiệm tốt nhất $A\mathbf{z}$ chính là *hình chiếu vuông góc* của $\mathbf{b}$ lên không gian cột của A. Sai số $\mathbf{b} - A\mathbf{z}$ vuông góc với mọi thứ ta dựng được từ A — nghĩa là ta đã vắt kiệt mọi thông tin mà A có thể giải thích. Phần dư còn lại là phần A *về nguyên tắc* không thể giải thích.
3. Trong code: đừng viết `inv(M.T @ M) @ M.T @ y`. Cách đó bình phương *số điều kiện* (condition number) của M, làm mất độ chính xác nghiêm trọng. Dùng:

- `numpy.linalg.lstsq(M, y, rcond=None)` — chuẩn mực, dựa trên SVD.
- `numpy.polyfit(x, y, deg)` — tiện cho đa thức.
- `sklearn.linear_model.LinearRegression` — khi cần thêm regularization, đánh giá, pipeline.

Đa thức xấp xỉ bình phương tối thiểu

Giả sử giờ ta muốn tìm một *đa thức*

$$y = f(x) = r_0 + r_1x + r_2x^2 + \cdots + r_mx^m$$

bậc m xấp xỉ tốt nhất các cặp dữ liệu $(x_1, y_1), \ldots, (x_n, y_n)$. Ta lại chọn các r_i sao cho

$$\|\mathbf{y} - f(\mathbf{x})\|^2 = [y_1 - f(x_1)]^2 + \cdots + [y_n - f(x_n)]^2$$

nhỏ nhất.

Định nghĩa 5.16 — Xấp xỉ bình phương tối thiểu

Đa thức $f(x)$ thỏa điều kiện trên được gọi là **đa thức xấp xỉ bình phương tối thiểu** bậc m cho các cặp dữ liệu đã cho.

Nếu viết

$$M = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^m \\ 1 & x_2 & x_2^2 & \cdots & x_2^m \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^m \end{bmatrix}, \qquad \mathbf{r} = \begin{bmatrix} r_0 \\ r_1 \\ \vdots \\ r_m \end{bmatrix}$$

(ma trận M này gọi là *ma trận Vandermonde*), ta thấy $f(\mathbf{x}) = M\mathbf{r}$. Vậy ta lại tìm xấp xỉ tốt nhất $\mathbf{z}$ cho hệ $M\mathbf{r} = \mathbf{y}$.

Định lý 5.6.3

Cho n cặp dữ liệu $(x_1, y_1), \ldots, (x_n, y_n)$, với M và $\mathbf{y}$ như trên.

1. Nếu $\mathbf{z}$ là nghiệm bất kỳ của hệ phương trình chuẩn tắc $(M^TM)\mathbf{z} = M^T\mathbf{y}$, thì đa thức

   $$z_0 + z_1x + z_2x^2 + \cdots + z_mx^m$$

   là một đa thức xấp xỉ bình phương tối thiểu bậc m cho dữ liệu đã cho.

2. Nếu ít nhất $m+1$ trong các số $x_1, \ldots, x_n$ là phân biệt (nên $n \geq m+1$), thì M^TM khả nghịch và $\mathbf{z}$ được xác định duy nhất bởi $\mathbf{z} = (M^TM)^{-1}M^T\mathbf{y}$.

Chứng minh. Còn phải chứng minh (2); ta chỉ ra các cột của M độc lập tuyến tính (Định lý 5.4.3). Giả sử một tổ hợp tuyến tính các cột triệt tiêu:

$$r_0 \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} + r_1 \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} + \cdots + r_m \begin{bmatrix} x_1^m \\ \vdots \\ x_n^m \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

Nếu đặt $q(x) = r_0 + r_1x + \cdots + r_mx^m$, so sánh từng thành phần cho

$$q(x_1) = q(x_2) = \cdots = q(x_n) = 0$$

Vậy $q(x)$ là đa thức bậc m có ít nhất $m+1$ nghiệm phân biệt, nên $q(x)$ phải là đa thức không. Do đó $r_0 = r_1 = \cdots = r_m = 0$. ■

Ví dụ 5.6.4

Tìm đa thức bậc hai xấp xỉ bình phương tối thiểu $y = z_0 + z_1x + z_2x^2$ cho các điểm dữ liệu

$$(-3, 3),\ (-1, 1),\ (0, 1),\ (1, 2),\ (3, 4)$$

Lời giải. Đây là trường hợp $m = 2$ của Định lý 5.6.3. Ta có

$$\mathbf{y} = \begin{bmatrix} 3 \\ 1 \\ 1 \\ 2 \\ 4 \end{bmatrix}, \qquad M = \begin{bmatrix} 1 & -3 & 9 \\ 1 & -1 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 3 & 9 \end{bmatrix}$$

Do đó

$$M^TM = \begin{bmatrix} 5 & 0 & 20 \\ 0 & 20 & 0 \\ 20 & 0 & 164 \end{bmatrix}, \qquad M^T\mathbf{y} = \begin{bmatrix} 11 \\ 4 \\ 66 \end{bmatrix}$$

Hệ phương trình chuẩn tắc cho $\mathbf{z}$ là

$$\begin{bmatrix} 5 & 0 & 20 \\ 0 & 20 & 0 \\ 20 & 0 & 164 \end{bmatrix}\mathbf{z} = \begin{bmatrix} 11 \\ 4 \\ 66 \end{bmatrix} \qquad \text{suy ra} \qquad \mathbf{z} = \begin{bmatrix} 1{,}15 \\ 0{,}20 \\ 0{,}26 \end{bmatrix}$$

Vậy đa thức bậc hai xấp xỉ bình phương tối thiểu là $y = 1{,}15 + 0{,}20x + 0{,}26x^2$.

Các hàm khác

Có một mở rộng của Định lý 5.6.3 đáng nhắc tới. Trong Định lý 5.6.3, $f(x)$ là tổ hợp tuyến tính của các hàm $1, x, x^2, \ldots, x^m$ với hệ số r_i. Điều này gợi ý áp dụng phương pháp cho các hàm khác. Nếu $f_0(x), f_1(x), \ldots, f_m(x)$ là các hàm cho trước, viết

$$f(x) = r_0f_0(x) + r_1f_1(x) + \cdots + r_mf_m(x)$$

Câu hỏi tổng quát hơn là liệu có tìm được $r_0, \ldots, r_m$ sao cho $\|\mathbf{y} - f(\mathbf{x})\|^2$ nhỏ nhất hay không. Hàm $f(x)$ như vậy gọi là **xấp xỉ bình phương tối thiểu tốt nhất** cho dữ liệu, trong họ hàm dạng $r_0f_0(x) + \cdots + r_mf_m(x)$.

Định lý 5.6.4

Cho n cặp dữ liệu $(x_1, y_1), \ldots, (x_n, y_n)$ và $m+1$ hàm $f_0(x), \ldots, f_m(x)$. Đặt

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \qquad M = \begin{bmatrix} f_0(x_1) & f_1(x_1) & \cdots & f_m(x_1) \\ f_0(x_2) & f_1(x_2) & \cdots & f_m(x_2) \\ \vdots & \vdots & & \vdots \\ f_0(x_n) & f_1(x_n) & \cdots & f_m(x_n) \end{bmatrix}, \qquad \mathbf{z} = \begin{bmatrix} z_0 \\ \vdots \\ z_m \end{bmatrix}$$

1. Nếu $\mathbf{z}$ là nghiệm bất kỳ của $(M^TM)\mathbf{z} = M^T\mathbf{y}$, thì hàm $z_0f_0(x) + z_1f_1(x) + \cdots + z_mf_m(x)$ là xấp xỉ tốt nhất cho dữ liệu này trong mọi hàm dạng $r_0f_0(x) + \cdots + r_mf_m(x)$.
2. Nếu M^TM khả nghịch (tức $\text{rank}(M) = m+1$), thì $\mathbf{z}$ được xác định duy nhất: $\mathbf{z} = (M^TM)^{-1}(M^T\mathbf{y})$.

Rõ ràng Định lý 5.6.4 chứa Định lý 5.6.3 như trường hợp riêng, nhưng nói chung *không* có phép kiểm đơn giản cho việc M^TM có khả nghịch hay không — điều kiện phụ thuộc vào việc chọn các hàm $f_i(x)$.

Ví dụ 5.6.5

Cho các cặp dữ liệu $(-1, 0)$, $(0, 1)$, $(1, 4)$, tìm hàm xấp xỉ bình phương tối thiểu dạng $r_0x + r_1 2^x$.

Lời giải. Các hàm là $f_0(x) = x$ và $f_1(x) = 2^x$, nên

$$M = \begin{bmatrix} -1 & 2^{-1} \\ 0 & 2^0 \\ 1 & 2^1 \end{bmatrix} = \tfrac{1}{2}\begin{bmatrix} -2 & 1 \\ 0 & 2 \\ 2 & 4 \end{bmatrix}$$

Ở đây $M^TM = \frac{1}{4}\begin{bmatrix} 8 & 6 \\ 6 & 21 \end{bmatrix}$ khả nghịch, nên hệ phương trình chuẩn tắc

$$\tfrac{1}{4}\begin{bmatrix} 8 & 6 \\ 6 & 21 \end{bmatrix}\mathbf{z} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}$$

có nghiệm duy nhất $\mathbf{z} = \frac{1}{11}\begin{bmatrix} 10 \\ 16 \end{bmatrix}$. Vậy hàm khớp tốt nhất dạng $r_0x + r_1 2^x$ là

$$f(x) = \tfrac{10}{11}x + \tfrac{16}{11}2^x$$

Chú ý $f(\mathbf{x}) = \begin{bmatrix} f(-1) \\ f(0) \\ f(1) \end{bmatrix} = \begin{bmatrix} -2/11 \\ 16/11 \\ 42/11 \end{bmatrix}$, so với $\mathbf{y} = \begin{bmatrix} 0 \\ 1 \\ 4 \end{bmatrix}$.

Ghi chú cho người học — ”tuyến tính” ở đây nghĩa là gì

Định lý 5.6.4 chứa một điểm dễ nhầm nhưng rất quan trọng: mô hình $f(x) = r_0 2^x + r_1 \sin x + r_2 \log x$ *vẫn là mô hình tuyến tính*, dù các hàm thành phần cong queo thế nào. Lý do: ”tuyến tính” trong ”hồi quy tuyến tính” nói về *tham số* r_i, không phải về biến x. Miễn là f tuyến tính theo các r_i, toàn bộ máy móc bình phương tối thiểu áp dụng được, và ta có nghiệm dạng đóng.

Đây chính là ý tưởng của **feature engineering** trong machine learning: bạn giữ nguyên thuật toán hồi quy tuyến tính, nhưng biến đổi dữ liệu đầu vào thành các đặc trưng mới (x^2, $\log x$, $\sin x$, tích chéo x_1x_2…). Mô hình vẫn ”tuyến tính” theo nghĩa toán học, nhưng khớp được dữ liệu phi tuyến.

Ngược lại, $f(x) = r_0 e^{r_1 x}$ *không* tuyến tính theo tham số (r_1 nằm trong số mũ), nên không giải bằng hệ phương trình chuẩn tắc được — phải dùng tối ưu hóa phi tuyến (gradient descent, Levenberg–Marquardt…).

Cảnh báo quan trọng: tăng bậc m luôn làm giảm sai số trên dữ liệu huấn luyện, và với $m = n - 1$ đa thức sẽ đi qua *chính xác* mọi điểm. Nhưng đó là **overfitting** — mô hình học thuộc cả nhiễu. Ma trận Vandermonde cũng trở nên cực kỳ ill-conditioned khi m lớn. Quy tắc thực hành: giữ m nhỏ, và luôn đánh giá trên dữ liệu mà mô hình chưa thấy.

5.7 Ứng dụng vào tương quan và phương sai

Giả sử ta đo chiều cao $h_1, h_2, \ldots, h_n$ của n người đàn ông. Tập dữ liệu như vậy gọi là một **mẫu** (sample) chiều cao của toàn bộ đàn ông trong quần thể đang nghiên cứu, và người ta thường đặt nhiều câu hỏi về mẫu đó: chiều cao trung bình là bao nhiêu? Mức biến động trong mẫu là bao nhiêu, đo thế nào? Từ mẫu có thể suy ra gì về chiều cao của tất cả đàn ông trong quần thể?

Việc phân tích mẫu và các suy luận rút ra từ mẫu là chủ đề của **thống kê toán học**. Trong mục này ta mô tả vài cách đại số tuyến tính được dùng ở đó.

Thuận tiện nhất là biểu diễn mẫu $\{x_1, x_2, \ldots, x_n\}$ dưới dạng **vector mẫu** $\mathbf{x} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix}$ trong $\mathbb{R}^n$ (ở đây ta viết vector dạng hàng cho tiện). Khi đó tích vô hướng trong $\mathbb{R}^n$ trở thành công cụ tiện lợi để nghiên cứu mẫu.

Thống kê nổi tiếng nhất mô tả một tập dữ liệu là **trung bình mẫu** (sample mean) $\overline{x}$:

$$\overline{x} = \tfrac{1}{n}(x_1 + x_2 + \cdots + x_n) = \tfrac{1}{n}\sum_{i=1}^{n} x_i$$

Trung bình $\overline{x}$ là giá trị "điển hình" của mẫu, nhưng bản thân nó có thể không phải là một giá trị trong mẫu. Số $x_i - \overline{x}$ gọi là **độ lệch** (deviation) của x_i so với trung bình. Hơn nữa, tổng các độ lệch bằng không:

$$\sum_{i=1}^{n}(x_i - \overline{x}) = \left(\sum_{i=1}^{n} x_i\right) - n\overline{x} = n\overline{x} - n\overline{x} = 0 \tag{5.6}$$

Ta mô tả điều này bằng cách nói trung bình mẫu $\overline{x}$ *nằm ở trung tâm* của các giá trị mẫu.

Nếu trừ $\overline{x}$ khỏi mỗi giá trị x_i, dữ liệu thu được $x_i - \overline{x}$ được gọi là đã **quy tâm** (centred). Vector dữ liệu tương ứng là

$$\mathbf{x}_c = \begin{bmatrix} x_1 - \overline{x} & x_2 - \overline{x} & \cdots & x_n - \overline{x} \end{bmatrix}$$

và (5.6) cho thấy $\overline{x_c} = 0$. Chẳng hạn với mẫu $\mathbf{x} = \begin{bmatrix} -1 & 0 & 1 & 4 & 6 \end{bmatrix}$, trung bình là $\overline{x} = 2$, và mẫu đã quy tâm là $\mathbf{x}_c = \begin{bmatrix} -3 & -2 & -1 & 2 & 4 \end{bmatrix}$. Vậy tác dụng của quy tâm là *dịch chuyển* dữ liệu một lượng $\overline{x}$ sao cho trung bình chuyển về 0.

Một câu hỏi khác là mẫu có *độ biến động* bao nhiêu — dữ liệu "trải rộng" quanh trung bình $\overline{x}$ đến mức nào. Thước đo tự nhiên sẽ là tổng các độ lệch, nhưng tổng đó bằng 0 theo (5.6); các độ lệch triệt tiêu lẫn nhau. Để tránh điều này, các nhà thống kê dùng *bình phương* $(x_i - \overline{x})^2$ của các độ lệch. Chính xác hơn, họ tính **phương sai mẫu** (sample variance) s_x^2:

$$s_x^2 = \frac{1}{n-1}\left[(x_1 - \overline{x})^2 + (x_2 - \overline{x})^2 + \cdots + (x_n - \overline{x})^2\right] = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2$$

Phương sai mẫu sẽ *lớn* nếu có nhiều x_i ở xa trung bình, và *nhỏ* nếu mọi x_i tụ sát quanh trung bình. Phương sai rõ ràng không âm (do đó ký hiệu s_x^2), và căn bậc hai s_x của nó gọi là **độ lệch chuẩn mẫu** (sample standard deviation).[5]

Trung bình và phương sai mẫu mô tả tiện lợi bằng tích vô hướng. Đặt $\mathbf{1} = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix}$. Nếu $\mathbf{x} = \begin{bmatrix} x_1 & \cdots & x_n \end{bmatrix}$ thì $\mathbf{x} \cdot \mathbf{1} = x_1 + \cdots + x_n$, nên

$$\overline{x} = \tfrac{1}{n}(\mathbf{x} \cdot \mathbf{1})$$

Hơn nữa, vì $\overline{x}$ là một vô hướng, ta có $\overline{x}\mathbf{1} = \begin{bmatrix} \overline{x} & \cdots & \overline{x} \end{bmatrix}$, nên vector mẫu quy tâm là

$$\mathbf{x}_c = \mathbf{x} - \overline{x}\mathbf{1}$$

Từ đó ta có công thức cho phương sai mẫu:

$$s_x^2 = \frac{1}{n-1}\|\mathbf{x}_c\|^2 = \frac{1}{n-1}\|\mathbf{x} - \overline{x}\mathbf{1}\|^2$$

[5] Vì có n giá trị mẫu, chia cho n có vẻ tự nhiên hơn chia cho $n-1$. Lý do dùng $n-1$ là để s_x^2 trở thành ước lượng *tốt hơn* cho phương sai của toàn bộ quần thể mà mẫu được rút ra từ đó.

Hệ số tương quan

Đại số tuyến tính cũng hữu ích khi so sánh *hai* mẫu khác nhau. Xét hai ví dụ.

Bảng sau biểu diễn số ngày nghỉ ốm mỗi năm và số lần đi khám bác sĩ mỗi năm của 10 cá nhân:

Cá nhân	1	2	3	4	5	6	7	8	9	10
Số lần khám	2	6	8	1	5	10	3	9	7	4
Ngày nghỉ ốm	2	4	8	3	5	9	4	7	7	2

Vẽ lên biểu đồ phân tán (scatter diagram), ta thấy rõ: càng đi khám nhiều thì càng nghỉ ốm nhiều. Đây là ví dụ về **tương quan dương** (positive correlation).

Giờ xét bảng biểu diễn liều vitamin C hằng ngày và số ngày nghỉ ốm:

Cá nhân	1	2	3	4	5	6	7	8	9	10
Vitamin C	1	5	7	0	4	9	2	8	6	3
Ngày nghỉ ốm	5	2	2	6	2	1	4	3	2	5

Ở đây có vẻ càng dùng nhiều vitamin C thì càng ít nghỉ ốm — **tương quan âm** (negative correlation).

Trong cả hai tình huống ta có **mẫu ghép cặp** (paired samples): quan sát hai biến trên cùng mười cá nhân. Có một cách dùng mẫu để tính ra một số, gọi là **hệ số tương quan**, đo mức độ liên hệ giữa hai biến.

Cho hai mẫu ghép cặp $\mathbf{x}$ và $\mathbf{y}$, xét các mẫu quy tâm $\mathbf{x}_c$ và $\mathbf{y}_c$. Nếu x_k lớn trong các x_i thì độ lệch $x_k - \overline{x}$ dương; và âm nếu x_k nhỏ. Tình huống với $\mathbf{y}$ tương tự. Bảng sau cho dấu của $(x_i - \overline{x})(y_i - \overline{y})$ trong cả bốn trường hợp:

Dấu của $(x_i - \overline{x})(y_i - \overline{y})$	x_i lớn	x_i nhỏ
y_i lớn	dương	âm
y_i nhỏ	âm	dương

Trực giác: nếu $\mathbf{x}$ và $\mathbf{y}$ tương quan dương thì (1) các x_i lớn thường đi kèm các y_i lớn, và (2) các x_i nhỏ thường đi kèm các y_i nhỏ. Từ bảng suy ra: nếu $\mathbf{x}$ và $\mathbf{y}$ tương quan dương thì tích vô hướng

$$\mathbf{x}_c \cdot \mathbf{y}_c = \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})$$

là *dương*. Tương tự $\mathbf{x}_c \cdot \mathbf{y}_c$ âm nếu tương quan âm. Với ý đó, **hệ số tương quan mẫu** r được định nghĩa bởi[6]

$$r = r(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x}_c \cdot \mathbf{y}_c}{\|\mathbf{x}_c\| \, \|\mathbf{y}_c\|}$$

Nhớ lại tình huống trong $\mathbb{R}^3$: r chính là **cosin của "góc"** giữa hai vector $\mathbf{x}_c$ và $\mathbf{y}_c$. Vậy ta kỳ vọng nó nằm giữa -1 và 1, và gần 1 (hoặc -1) nếu hai vector cùng hướng (hoặc ngược hướng).

[6] Ý tưởng dùng một con số duy nhất để đo mức độ liên hệ giữa các biến do Francis Galton (1822–1911) khởi xướng khi nghiên cứu mức độ đặc điểm con cái liên hệ với cha mẹ. Ý tưởng được Karl Pearson (1857–1936) tinh chỉnh, và r thường được gọi là *hệ số tương quan Pearson*.

Điều này được xác nhận bởi Định lý 5.7.1 dưới đây, và cũng đúng trong các ví dụ trên: tương quan giữa ngày nghỉ ốm và số lần khám bác sĩ là $r = 0{,}90$; còn tương quan giữa liều vitamin C và ngày nghỉ ốm là $r = -0{,}84$.

CẢNH BÁO QUAN TRỌNG — tương quan không phải nhân quả

Ta **không thể** kết luận từ ví dụ thứ hai rằng uống nhiều vitamin C hơn sẽ làm giảm số ngày nghỉ ốm. Tương quan (âm) có thể phát sinh vì một *yếu tố thứ ba* liên quan tới cả hai biến. Chẳng hạn, có thể những người sức khỏe kém hơn có xu hướng uống nhiều vitamin C hơn.

Tương quan không hàm ý nhân quả (correlation does not imply causation).

Tương tự, tương quan giữa ngày nghỉ ốm và số lần đi khám *không* có nghĩa là nghỉ ốm nhiều *gây ra* việc đi khám nhiều. Tương quan giữa hai biến có thể chỉ ra sự tồn tại của các yếu tố tiềm ẩn khác, nhưng không nhất thiết có quan hệ nhân quả giữa chúng.

Định lý 5.7.1

Cho $\mathbf{x}$ và $\mathbf{y}$ là các mẫu ghép cặp (khác không), và $r = r(\mathbf{x}, \mathbf{y})$ là hệ số tương quan. Khi đó:

1. $-1 \le r \le 1$.
2. $r = 1$ khi và chỉ khi tồn tại a và $b > 0$ sao cho $y_i = a + bx_i$ với mọi i.
3. $r = -1$ khi và chỉ khi tồn tại a và $b < 0$ sao cho $y_i = a + bx_i$ với mọi i.

Chứng minh. Bất đẳng thức Cauchy (Định lý 5.3.2) chứng minh (1), và cũng cho thấy $r = \pm 1$ khi và chỉ khi một trong $\mathbf{x}_c$, $\mathbf{y}_c$ là bội vô hướng của vector kia. Điều này lại đúng khi và chỉ khi $\mathbf{y}_c = b\mathbf{x}_c$ với $b \neq 0$ nào đó, và dễ kiểm tra $r = 1$ khi $b > 0$, $r = -1$ khi $b < 0$.

Cuối cùng, $\mathbf{y}_c = b\mathbf{x}_c$ nghĩa là $y_i - \overline{y} = b(x_i - \overline{x})$ với mọi i; tức $y_i = a + bx_i$ với $a = \overline{y} - b\overline{x}$. Ngược lại, nếu $y_i = a + bx_i$ thì $\overline{y} = a + b\overline{x}$, nên $y_i - \overline{y} = (a + bx_i) - (a + b\overline{x}) = b(x_i - \overline{x})$ với mọi i. Nói cách khác $\mathbf{y}_c = b\mathbf{x}_c$. $\blacksquare$

Tính chất (2) và (3) cho thấy $r(\mathbf{x}, \mathbf{y}) = 1$ nghĩa là có quan hệ tuyến tính với *hệ số góc dương* giữa dữ liệu ghép cặp; còn $r(\mathbf{x}, \mathbf{y}) = -1$ nghĩa là quan hệ tuyến tính với *hệ số góc âm*.

Công thức tính toán

Cuối cùng ta dùng tích vô hướng để suy ra vài công thức tiện cho việc tính phương sai và hệ số tương quan. Quan sát then chốt là công thức sau:

$$\mathbf{x}_c \cdot \mathbf{y}_c = \mathbf{x} \cdot \mathbf{y} - n\,\overline{x}\,\overline{y} \tag{5.7}$$

Thật vậy, nhớ rằng $\overline{x}$ và $\overline{y}$ là vô hướng:

$$\begin{aligned} \mathbf{x}_c \cdot \mathbf{y}_c &= (\mathbf{x} - \overline{x}\mathbf{1}) \cdot (\mathbf{y} - \overline{y}\mathbf{1}) \\ &= \mathbf{x} \cdot \mathbf{y} - \mathbf{x} \cdot (\overline{y}\mathbf{1}) - (\overline{x}\mathbf{1}) \cdot \mathbf{y} + (\overline{x}\mathbf{1}) \cdot (\overline{y}\mathbf{1}) \\ &= \mathbf{x} \cdot \mathbf{y} - \overline{y}(\mathbf{x} \cdot \mathbf{1}) - \overline{x}(\mathbf{1} \cdot \mathbf{y}) + \overline{x}\,\overline{y}(\mathbf{1} \cdot \mathbf{1}) \\ &= \mathbf{x} \cdot \mathbf{y} - \overline{y}(n\overline{x}) - \overline{x}(n\overline{y}) + \overline{x}\,\overline{y}\,n \\ &= \mathbf{x} \cdot \mathbf{y} - n\,\overline{x}\,\overline{y} \end{aligned}$$

Lấy $\mathbf{y} = \mathbf{x}$ trong (5.7) cho công thức phương sai:

Định lý — Công thức phương sai

Nếu $\mathbf{x}$ là vector mẫu, thì

$$s_x^2 = \frac{1}{n-1}\left(\|\mathbf{x}\|^2 - n\,\overline{x}^2\right)$$

Định lý — Công thức tương quan

Nếu $\mathbf{x}$ và $\mathbf{y}$ là các vector mẫu, thì

$$r = r(\mathbf{x},\mathbf{y}) = \frac{\mathbf{x}\cdot\mathbf{y} - n\,\overline{x}\,\overline{y}}{(n-1)s_x s_y}$$

Cuối cùng, một phương pháp làm đơn giản việc tính phương sai và tương quan:

Định lý — Co giãn dữ liệu (Data Scaling)

Cho các vector mẫu $\mathbf{x}$ và $\mathbf{y}$. Với các hằng số a, b, c, d, xét các mẫu mới $\mathbf{z}$ và $\mathbf{w}$ với $z_i = a + bx_i$ và $w_i = c + dy_i$ với mọi i. Khi đó:

a. $\overline{z} = a + b\overline{x}$

b. $s_z^2 = b^2 s_x^2$, nên $s_z = |b|\, s_x$

c. Nếu b và d cùng dấu, thì $r(\mathbf{x},\mathbf{y}) = r(\mathbf{z},\mathbf{w})$.

Chẳng hạn, nếu $\mathbf{x} = \begin{bmatrix}101 & 98 & 103 & 99 & 100 & 97\end{bmatrix}$, trừ đi 100 cho $\mathbf{z} = \begin{bmatrix}1 & -2 & 3 & -1 & 0 & -3\end{bmatrix}$. Tính toán thường quy cho $\overline{z} = -\frac{1}{3}$ và $s_z^2 = \frac{14}{3}$, nên

$$\overline{x} = 100 - \tfrac{1}{3} \approx 99{,}67, \qquad s_x^2 = s_z^2 = \tfrac{14}{3} \approx 4{,}67$$

Ghi chú cho người học — tương quan Pearson chính là cosine similarity

Đây là điểm đẹp nhất của mục 5.7 và rất đáng ghi nhớ cho ngành của bạn:

$$r(\mathbf{x},\mathbf{y}) = \frac{\mathbf{x}_c\cdot\mathbf{y}_c}{\|\mathbf{x}_c\|\|\mathbf{y}_c\|} = \cos(\text{góc giữa } \mathbf{x}_c \text{ và } \mathbf{y}_c)$$

Nói cách khác: **tương quan Pearson = cosine similarity trên dữ liệu đã quy tâm**. Hai khái niệm bạn gặp ở hai môn khác nhau (thống kê và tìm kiếm ngữ nghĩa) thực ra là *cùng một công thức*.
Điều đó giải thích ngay vì sao $-1 \le r \le 1$: vì cosin luôn nằm trong khoảng đó, và điều đó lại do bất đẳng thức Cauchy (Định lý 5.3.2) bảo đảm.
Ứng dụng cụ thể:

- **Hệ gợi ý** (recommender system): độ tương đồng giữa hai người dùng thường tính bằng đúng r trên vector đánh giá của họ. Việc quy tâm quan trọng — nó loại bỏ thói quen "người này chấm điểm rộng, người kia chấm chặt".
- **Chọn đặc trưng** (feature selection): hai đặc trưng có $|r|$ gần 1 là dư thừa; giữ cả hai gây đa cộng tuyến, làm A^TA trong Mục 5.6 gần suy biến.
- **Phát hiện bất thường** (anomaly detection) trong bảo mật: ma trận tương quan của các chỉ số hệ thống (CPU, lưu lượng mạng, số lần đăng nhập thất bại) cho biết hành vi "bình thường". Tương quan bị phá vỡ đột ngột là tín hiệu đáng điều tra.
- **PCA**: bước đầu tiên chính là quy tâm dữ liệu, rồi lấy trị riêng của ma trận hiệp phương sai (hoặc tương quan) — nối thẳng về Mục 5.5.

Giới hạn cần nhớ: r chỉ đo quan hệ *tuyến tính*. Dữ liệu nằm hoàn hảo trên parabol $y = x^2$ đối xứng qua 0 cho $r = 0$ — quan hệ mạnh nhưng r không thấy. Luôn vẽ biểu đồ phân tán trước khi tin vào một con số r.

Tổng kết Chương 5 — bản đồ các khái niệm

Chương 5 nhìn có vẻ rời rạc, nhưng thực ra là một chuỗi liên tục:

Mục	Khái niệm cốt lõi	Nối vào đâu
5.1	Không gian con, span	Định nghĩa ”sân chơi”: tập con nào đóng với phép cộng và nhân vô hướng
5.2	Độc lập, cơ sở, số chiều	Đo ”kích thước” của sân chơi đó bằng một con số
5.3	Trực giao, cơ sở trực giao	Chọn hệ trục *vuông góc* $\Rightarrow$ tọa độ tính bằng tích vô hướng
5.4	Hạng, Rank–Nullity	Nối ma trận với số chiều: mỗi ma trận sinh ra 4 không gian con
5.5	Đồng dạng, chéo hóa	Đổi cơ sở sang cơ sở vector riêng $\Rightarrow$ ma trận thành đường chéo
5.6	Bình phương tối thiểu	Khi hệ vô nghiệm: chiếu vuông góc lên không gian cột (dùng 5.3 + 5.4)
5.7	Tương quan	Cosin của góc giữa hai vector dữ liệu quy tâm (dùng 5.3)

Một câu tóm tắt cả chương: *Đại số tuyến tính cho phép ta chọn hệ tọa độ tốt nhất cho bài toán — và ”tốt nhất” thường nghĩa là trực giao hoặc chéo hóa.*
Chuẩn bị cho Chương 6: Chương 6 sẽ lấy mọi thứ bạn vừa học trong $\mathbb{R}^n$ và *trừu tượng hóa* — áp dụng cho không gian đa thức, không gian ma trận, không gian hàm số. Các định lý gần như giống hệt; chỉ khác là ”vector” không còn là bộ n số nữa. Nếu bạn nắm chắc Chương 5, Chương 6 chủ yếu là việc *nhận ra cùng một cấu trúc ở nơi khác*.

Chương 5 — Không gian vector $\mathbb{R}^n$ — bản dịch tiếng Việt gồm bảng thuật ngữ và toàn bộ 7 mục 5.1–5.7 (định nghĩa, định lý, chứng minh, ví dụ có lời giải).

Phần bài tập (Exercises) của Chương 5 không được dịch trong bản này — xin xem trực tiếp bản gốc tiếng Anh, trang 267–326.

Một số hình minh họa hình học trong bản gốc không được vẽ lại; các vị trí đó đều có ghi chú nhắc bạn đối chiếu bản gốc.

Bản dịch dựa trên *Linear Algebra with Applications*, W. Keith Nicholson, Lyryx Open Edition (Version 2023 — Revision A), phát hành theo giấy phép **CC BY-NC-SA 4.0**. Bản dịch này là một tác phẩm phái sinh và cũng được phát hành theo cùng giấy phép CC BY-NC-SA 4.0.